기계학습프로그래밍 HW4. 이진 분류 모델 구현

- **당뇨병 판단 모델 구현**
  - 수업 시간에 작성한 클래스(Own_ML_Class.py) 사용할 것
  - 교수님께서 제공하신 파일 사용
  - 필요 시 데이터 전처리 할 것
  - 평가는 마지막 row 20개를 대상으로 0/1을 얼마나 잘 맞추었는지로 accuracy 계산
    - 예: 16/20 => 80%, 18/20 => 90%

- **타이타닉 생존 여부 판단 모델 구현**
  - 데이터 전처리 실습시간에 SVM 기반 모델에서 사용한 전처리한 데이터셋 사용 가능
  - SVM vs. Logistic Regression(Binary Classification) 성능 비교
    - 마지막 row 20개를 대상으로 0/1을 얼마나 잘 맞추었는지 간단하게 비교 평가해볼 것.

■ 데이터셋 파악

(i) 데이터 생김새를 먼저 살펴볼거다.

원본 데이터를 먼저 볼 것이다. [Kaggle에서 구할 수 있다.]

	A	B	C	D	E	F	G	H	I
1	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
2	6	148	72	35	0	33.6	0.627	50	1
3	1	85	66	29	0	26.6	0.351	31	0
4	8	183	64	0	0	23.3	0.672	32	1
5	1	89	66	23	94	28.1	0.167	21	0
6	0	137	40	35	168	43.1	2.288	33	1
7	5	116	74	0	0	25.6	0.201	30	0
8	3	78	50	32	88	31	0.248	26	1
9	10	115	0	0	0	35.3	0.134	29	0
10	2	197	70	45	543	30.5	0.158	53	1
11	8	125	96	0	0	0	0.232	54	1
12	4	110	92	0	0	37.6	0.191	30	0
13	10	168	74	0	0	38	0.537	34	1
14	10	139	80	0	0	27.1	1.441	57	0
15	1	189	60	23	846	30.1	0.398	59	1
16	5	166	72	19	175	25.8	0.587	51	1
17	7	100	0	0	0	30	0.484	32	1
18	0	118	84	47	230	45.8	0.551	31	1
19	7	107	74	0	0	29.6	0.254	31	1
20	1	103	30	38	83	43.3	0.183	33	0
21	1	115	70	30	96	34.6	0.529	32	1
22	3	126	88	41	235	39.3	0.704	27	0
23	8	99	84	0	0	35.4	0.388	50	0
24	7	196	90	0	0	39.8	0.451	41	1
25	9	119	80	35	0	29	0.263	29	1
26	11	143	94	33	146	36.6	0.254	51	1
27	10	125	70	26	115	31.1	0.205	41	1
28	7	147	76	0	0	39.4	0.257	43	1
29	1	97	66	15	140	23.2	0.487	22	0
30	13	145	82	19	110	22.2	0.245	57	0
31	5	117	92	0	0	34.1	0.337	38	0

diabetes

준비 평균: 0.348958333 개수: 769 합계: 268

[1]정식 명칭은 **Pima Indians Diabetes Database.**

총 760개의 행, 9열로 이루어진 데이터셋이다.

(6개의 혈청 측정치를 받아 질병 진행을 예측하는 다른 Diabete 데이터셋이 있으므로 헷갈리지 않도록 조심해야 한다. 그 데이터셋은 442개의 행, 10개의 열로 구성되어 있다.)

- **Pregnancies** : 임신 여부(횟수?)
- **Glucose**: 포도당 수치
- **BloodPressure**: 혈압(mm Hg_)
- **SkinThickness**: 팔삼두근 뒤쪽의 피하지방 측정값(mm) = 피부의 두께
- **Insulin**: 인슐린 수치(mm U/ml)
- **BMI**: 체질량 지수
- **DiabetesPedigreeFunction**: 당뇨 혈통 함수(당뇨 내력 가중치 값 := 가족력?)
- **Age**: 나이
- **Diabetes**: 당뇨 여부, 예측 목표값
  - 이 모델의 Target 데이터.

(ii) 목표

Pima Indians Diabetes Database는 북아메리카 피마 지역 원주민의 Type-2 당뇨병 결과 데이터이다.
약 760명의 원주민의 8가지 진단값을 기록해두었다.
이 데이터셋을 인공지능에 학습시켜 주로 어떤 수치를 가지는 원주민이 당뇨병에 걸리는지 예측하는 모델을 만들고자 한다.

(iii) 방법

우선 교수님이 사용하라고 권고하신 데이터 파일은 아래와 같다.

	A	B	C	D	E	F	G	H	I
1	-0.29412	0.487437	0.180328	-0.29293	0	0.00149	-0.53117	-0.03333	0
2	-0.88235	-0.14573	0.081967	-0.41414	0	-0.20715	-0.76687	-0.66667	1
3	-0.05882	0.839196	0.04918	0	0	-0.30551	-0.49274	-0.63333	0
4	-0.88235	-0.10553	0.081967	-0.53535	-0.77778	-0.16244	-0.924	0	1
5	0	0.376884	-0.34426	-0.29293	-0.60284	0.28465	0.887276	-0.6	0
6	-0.41177	0.165829	0.213115	0	0	-0.23696	-0.89496	-0.7	1
7	-0.64706	-0.21608	-0.18033	-0.35354	-0.79196	-0.07601	-0.85483	-0.83333	0
8	0.176471	0.155779	0	0	0	0.052161	-0.95218	-0.73333	1
9	-0.76471	0.979899	0.147541	-0.09091	0.283688	-0.09091	-0.93168	0.066667	0
10	-0.05882	0.256281	0.57377	0	0	0	-0.86849	0.1	0
11	-0.52941	0.105528	0.508197	0	0	0.120715	-0.9035	-0.7	1
12	0.176471	0.688442	0.213115	0	0	0.132638	-0.60803	-0.56667	0
13	0.176471	0.396985	0.311475	0	0	-0.19225	0.163962	0.2	1
14	-0.88235	0.899497	-0.01639	-0.53535	1	-0.10283	-0.72673	0.266667	0
15	-0.17647	0.005025	0	0	0	-0.10581	-0.65329	-0.63333	0
16	0	0.18593	0.377049	-0.05051	-0.45627	0.365127	-0.59607	-0.66667	0
17	-0.17647	0.075377	0.213115	0	0	-0.11774	-0.8497	-0.66667	0
18	-0.88235	0.035176	-0.5082	-0.23232	-0.80378	0.290611	-0.91033	-0.6	1

컬럼명이 삭제되어 있으며, 위의 원본 데이터와는 달리 수치들이 [-2,2] 안쪽에서만 노닌다. 혈압과 나이처럼 원래였다면 음수가 될 수 없는 수치들도 예외는 없다.

이는 이 데이터셋이 이미 표준화가 적용되어 평균을 기준으로 하는 상대적인 편차로 변환되었기 때문이다.

- **마이너스(-)** : 해당 환자의 특성값이 전체 평균보다 낮음
- **플러스(+)** : 해당 환자의 특성값이 전체 평균보다 높음
- 0 : 전체 평균과 정확히 일치

우선 다루기 편하도록 데이터셋에 컬럼명을 지어줄 것이다.

(여기부터 정리 중……)

특정 열 제목을 데이터의 첫 번째 행으로 넣기만약 열 제목 자체를 데이터 값으로 인식시켜 행으로 추가하고 싶은 경우, pd.concat을 이용해 새 행으로 붙일 수 있습니다.python# 열 제목을 리스트로 추출하여 새 행 데이터 생성

```
new_row = pd.DataFrame([df.columns.tolist()], columns=df.columns)
# 기존 데이터프레임 맨 위에 추가
df_added = pd.concat([new_row, df], ignore_index=True)
```

+ 표준화 개념 정리

1) Kisoo의 공부 기록장, [파이썬 머신러닝 완벽 가이드] 3장. (4) 피마 인디언 당뇨병 예측