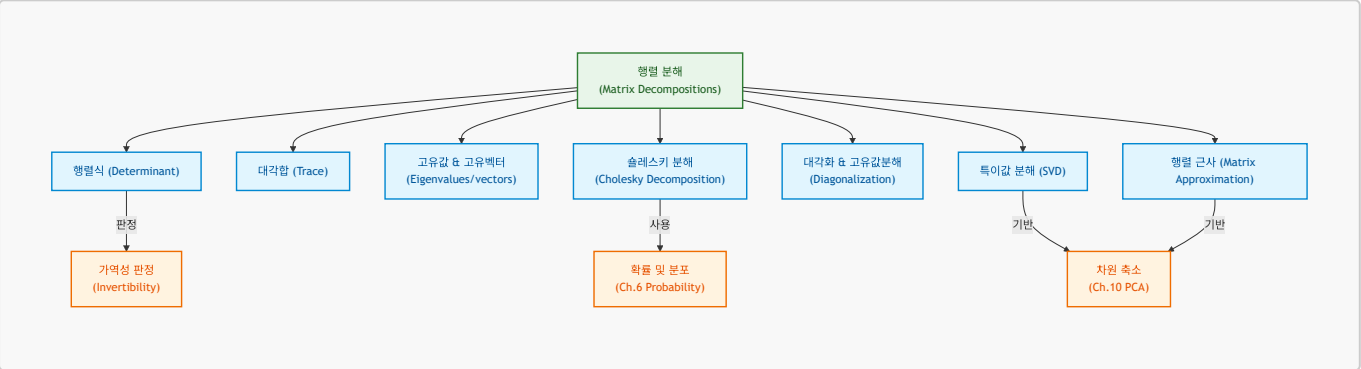
4. 행렬 분해 (Matrix Decompositions)

선형대수와 해석기하학의 기초를 바탕으로, 본 장에서는 행렬과 선형 사상의 핵심 물리적 특성을 숫자로 요약하는 방법과 대형 행렬을 다루기 쉬운 기본 인자 행렬들의 곱으로 쪼개는 **행렬 분해(Matrix Decomposition / Matrix Factorization)** 기법들을 다룹니다.

행렬 분해는 정수를 소수들의 곱(예: $21 = 7 \times 3$)으로 분해하여 수의 성질을 파악하는 것과 유사합니다. 대규모 데이터나 복잡한 선형 변환을 기하학적·대수적으로 해석하기 쉬운 특수한 행렬(삼각행렬, 대각행렬, 직교행렬 등)의 곱으로 표현함으로써 계산 효율성을 극대화하고 머신러닝 알고리즘의 수치적 안정성을 보장합니다.

[시각 자료] 행렬 분해 개념 마인드맵 (Figure 4.1)

본 장에서 다루는 주요 개념과 이들이 머신러닝의 다른 장에서 어떻게 응용되는지 보여주는 도식입니다.



4.1 행렬식과 대각합 (Determinant and Trace)

행렬식과 대각합은 정사각 행렬 $A \in \mathbb{R}^{n \times n}$의 전반적인 성질을 단 하나의 실수(scalar)로 요약하여 나타내는 대표적인 함수입니다.

4.1.1 행렬식 (Determinant)

행렬식은 선형 연립방정식의 해의 존재 여부를 분석하고 판별하는 데 사용되는 핵심 대수적 도구입니다. 오직 정사각 행렬 $A \in \mathbb{R}^{n \times n}$에 대해서만 정의되며, $\det(A)$ 또는 $|A|$로 표기합니다.

$$\det(A) = \begin{vmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{vmatrix} \tag{4.1}$$

행렬식은 정사각 행렬을 입력받아 실수를 출력하는 함수입니다. 일반적인 $n \times n$ 차원의 행렬식을 정의하기에 앞서, 작은 크기의 행렬식과 특수 행렬의 행렬식을 살펴보겠습니다.

[정리 4.1] 행렬의 가역성과 행렬식

임의의 정사각 행렬 $A \in \mathbb{R}^{n \times n}$에 대하여, **$A$가 역행렬을 가질(invertible) 필요충분조건은 $\det(A) \neq 0$인 것이다.** 즉,

$$A \text{ is invertible} \iff \det(A) \neq 0$$

소형 행렬의 행렬식 공식

- 1×1 **행렬**: Scalar 값 자체가 행렬식이 됩니다.

$$\det(A) = \det(a_{11}) = a_{11} \tag{4.5}$$

- 2×2 **행렬**: 역행렬 공식 $A^{-1} = \frac{1}{a_{11}a_{22} - a_{12}a_{21}} \begin{bmatrix} a_{22} & -a_{12} \\ -a_{21} & a_{11} \end{bmatrix}$의 분모 항에 해당합니다.

$$\det(A) = \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} = a_{11}a_{22} - a_{12}a_{21} \tag{4.6}$$

- 3×3 **행렬 (사루스 법칙, Sarrus' Rule)**: diagonal 방향 곱들의 합에서 반대 대각 방향 곱들의 합을 빼서 계산합니다.

$$\begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} = a_{11}a_{22}a_{33} + a_{21}a_{32}a_{13} + a_{31}a_{12}a_{23} - a_{31}a_{22}a_{13} - a_{11}a_{32}a_{23} - a_{21}a_{12}a_{33} \tag{4.7}$$

삼각행렬의 행렬식

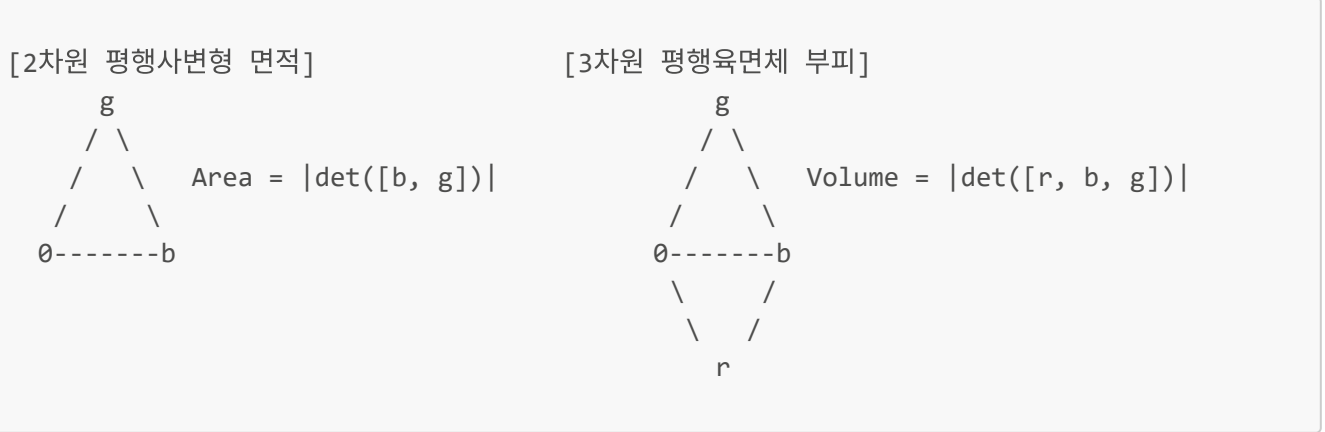
주대각선 성분의 아래쪽 성분이 모두 0인 **상삼각행렬 (Upper-triangular matrix)** 또는 주대각선의 위쪽 성분이 모두 0인 **하삼각행렬 (Lower-triangular matrix)** $T \in \mathbb{R}^{n \times n}$의 행렬식은 단순히 **주대각선 성분들의 곱**입니다.

$$\det(T) = \prod_{i=1}^{n} T_{ii} \tag{4.8}$$

[시각 자료] 행렬식의 기하학적 의미 (Figure 4.2 & 4.3)

행렬식은 행렬의 열벡터들이 형성하는 도형의 **유향 부피(Signed Volume)**를 나타냅니다.

- 2차원 공간에서 두 열벡터 $\mathbf{b}$와 $\mathbf{g}$가 이루는 평행사변형의 넓이는 $|\det([\mathbf{b}, \mathbf{g}])|$입니다. 두 벡터가 선형 종속(일직선상에 존재)이 되면 넓이는 0이 됩니다.
- 3차원 공간에서 세 열벡터 $\mathbf{r}, \mathbf{b}, \mathbf{g}$가 이루는 평행육면체의 부피는 $|\det([\mathbf{r}, \mathbf{b}, \mathbf{g}])|$입니다.
- 행렬식의 **부호(Sign)**는 표준 기저에 대한 열벡터들의 **지향성(Orientation)**을 나타냅니다. 열벡터의 순서를 바꾸면(우방향계에서 좌방향계로 변경 등) 부호가 뒤집힙니다.



[예제 4.2] 3차원 부피 계산

다음과 같이 정의된 3차원 공간의 세 선형 독립 벡터 $\mathbf{r}, \mathbf{g}, \mathbf{b} \in \mathbb{R}^3$가 있습니다.

$$\mathbf{r} = \begin{bmatrix} 2 \\ 0 \\ -8 \end{bmatrix}, \quad \mathbf{g} = \begin{bmatrix} 6 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ 4 \\ -1 \end{bmatrix} \tag{4.9}$$

이 벡터들을 열벡터로 가지는 행렬 A를 조립하면 다음과 같습니다.

$$A = [\mathbf{r}, \mathbf{g}, \mathbf{b}] = \begin{bmatrix} 2 & 6 & 1 \\ 0 & 1 & 4 \\ -8 & 0 & -1 \end{bmatrix} \tag{4.10}$$

이 세 벡터가 이루는 평행육면체의 부피 V는 행렬식의 절대값으로 계산됩니다.

$$V = |\det(A)| = 186 \tag{4.11}$$

라플라스 전개 (Laplace Expansion)

3×3보다 큰 일반적인 $n \times n$ 정사각 행렬의 행렬식을 계산하기 위해, 고차원 행렬식을 하위 차원인 $(n-1) \times (n-1)$ 정사각 행렬식들의 합으로 재귀적으로 환원시키는 **라플라스 전개 (여인수 전개)**를 사용합니다.

[정리 4.2] 라플라스 전개

정사각 행렬 $A \in \mathbb{R}^{n \times n}$에 대하여, 임의의 열 인덱스 $j \in \{1, \dots, n\}$ 또는 임의의 행 인덱스 $j \in \{1, \dots, n\}$를 선택하여 다음을 수행할 수 있습니다.

1. **j번째 열 기준 전개**:

$$\det(A) = \sum_{k=1}^{n} (-1)^{k+j} a_{kj} \det(A_{k,j}) \tag{4.12}$$

2. **j번째 행 기준 전개**:

$$\det(A) = \sum_{k=1}^{n} (-1)^{k+j} a_{jk} \det(A_{j,k}) \tag{4.13}$$

여기서 $A_{k,j} \in \mathbb{R}^{(n-1)\times(n-1)}$는 행렬 A에서 k번째 행과 j번째 열을 제거하고 남은 소행렬(Submatrix)입니다. 이때 $\det(A_{k,j})$를 **소행렬식(Minor)**이라 부르고, 부호를 포함한 $(-1)^{k+j}\det(A_{k,j})$를 **여인수(Cofactor)**라고 정의합니다.

[예제 4.3] 라플라스 전개 계산

다음 행렬 A의 행렬식을 첫 번째 행을 기준으로 전개하여 구합니다.

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 3 & 1 & 2 \\ 0 & 0 & 1 \end{bmatrix} \tag{4.14}$$

식 (4.13)을 적용하면 다음과 같습니다.

$$\det(A) = (-1)^{1+1} \cdot 1 \cdot \begin{vmatrix} 1 & 2 \\ 0 & 1 \end{vmatrix} + (-1)^{1+2} \cdot 2 \cdot \begin{vmatrix} 3 & 2 \\ 0 & 1 \end{vmatrix} + (-1)^{1+3} \cdot 3 \cdot \begin{vmatrix} 3 & 1 \\ 0 & 0 \end{vmatrix} \tag{4.15}$$

각 2×2 소행렬식을 계산하여 더합니다.

$$\det(A) = 1 \cdot (1 - 0) - 2 \cdot (3 - 0) + 3 \cdot (0 - 0) = 1 - 6 + 0 = -5 \tag{4.16}$$

참고로, 사루스 법칙(식 (4.7))을 적용해 계산해도 동일한 결과가 도출됩니다.

$$\det(A) = (1 \cdot 1 \cdot 1 + 3 \cdot 0 \cdot 3 + 0 \cdot 2 \cdot 2) - (0 \cdot 1 \cdot 3 + 1 \cdot 0 \cdot 2 + 3 \cdot 2 \cdot 1) = 1 - 6 = -5 \tag{4.17}$$

행렬식의 대수적 성질들

임의의 정사각 행렬 $A, B \in \mathbb{R}^{n \times n}$ 및 스칼라 $\lambda \in \mathbb{R}$에 대해 다음 성질들이 성립합니다.

- **곱의 행렬식**: $\det(AB) = \det(A)\det(B)$
- **전치 행렬식**: $\det(A) = \det(A^\top)$ (행과 열에 대한 연산 성질이 완전히 대칭적임을 뜻합니다.)
- **역행렬의 행렬식**: A가 가역일 때, $\det(A^{-1}) = \frac{1}{\det(A)}$
- **기저 변환(닮음) 불변성**: 닮음 관계($B = S^{-1}AS$)에 있는 행렬들은 동일한 행렬식을 가집니다. 따라서 선형 사상의 행렬식은 어떤 기저를 선택하여 표현하든 동일하게 보존됩니다.
- **기본 행 연산과 행렬식**:
  - 한 행(또는 열)에 다른 행(또는 열)의 배수를 더해도 행렬식은 변하지 않습니다 ($\det(A)$ 유지).
  - 한 행(또는 열)에 λ배를 곱하면 행렬식 전체가 λ배 스칼라배 됩니다. 따라서 $\det(\lambda A) = \lambda^n \det(A)$가 성립합니다.
  - 두 행(또는 열)을 서로 맞바꾸면 행렬식의 부호가 반대로 바뀝니다 ($-\det(A)$).

이 성질들을 이용하면, 복잡한 고차원 행렬식 계산 시 라플라스 전개를 반복하는 대신 **가우스 소거법**을 사용하여 행렬을 상삼각행렬 형태로 변환한 뒤 대각선 성분들만 곱함으로써 매우 효율적으로 행렬식을 계산할 수 있습니다.

[정리 4.3] 행렬식과 랭크의 관계

정사각 행렬 $A \in \mathbb{R}^{n \times n}$에 대하여,

$$\det(A) \neq 0 \iff \mathrm{rk}(A) = n$$

즉, 행렬식이 0이 아니라는 것은 행렬의 모든 열벡터가 선형 독립이며 풀 랭크(Full rank)를 가짐을 의미합니다.

4.1.2 대각합 (Trace)

대각합은 정사각 행렬 $A \in \mathbb{R}^{n \times n}$의 주대각선 성분들의 총합을 구하는 연산으로, $\mathrm{tr}(A)$로 표기합니다.

$$\mathrm{tr}(A) := \sum_{i=1}^{n} a_{ii} \tag{4.18}$$

대각합의 주요 성질

임의의 정사각 행렬 $A, B \in \mathbb{R}^{n \times n}$ 및 임의의 스칼라 $\alpha \in \mathbb{R}$에 대해 다음 성질들이 항상 만족됩니다.

1. **선형성**: $\mathrm{tr}(A + B) = \mathrm{tr}(A) + \mathrm{tr}(B)$
2. **비례성**: $\mathrm{tr}(\alpha A) = \alpha \mathrm{tr}(A)$
3. **단위행렬의 대각합**: $\mathrm{tr}(\mathbf{I}_n) = n$

4. **곱셈 교환의 순환 대칭성**: $A \in \mathbb{R}^{n\times k}$이고 $B \in \mathbb{R}^{k\times n}$일 때, 비록 두 행렬의 크기가 다르더라도 다음이 성립합니다.

$$\mathrm{tr}(AB) = \mathrm{tr}(BA) \tag{4.12}$$

이 네 가지 성질을 동시에 만족하는 유일한 선형 연산자가 바로 대각합입니다.

순환 대칭성의 일반화

대각합의 곱셈 순환 대칭성은 임의의 수의 행렬 곱으로 확장됩니다. 행렬 $A \in \mathbb{R}^{a\times k}, K \in \mathbb{R}^{k\times l}, L \in \mathbb{R}^{l\times a}$의 곱에 대해 다음이 성립합니다.

$$\mathrm{tr}(AKL) = \mathrm{tr}(KLA) = \mathrm{tr}(LAK) \tag{4.19}$$

단, 행렬의 순서가 순환적으로(cyclic) 회전하는 조합에 대해서만 성립하며, 임의로 순서를 바꾸는 일반적인 교환법칙($\mathrm{tr}(AKL) \neq \mathrm{tr}(ALK)$)은 성립하지 않으므로 주의해야 합니다.

[특수 사례] 벡터의 외적과 내적의 관계

두 벡터 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$에 의해 생성되는 $n \times n$ 외적 행렬(Outer product) $\mathbf{x}\mathbf{y}^\top$의 대각합은 두 벡터의 내적(Inner product)과 동일합니다.

$$\mathrm{tr}(\mathbf{x}\mathbf{y}^\top) = \mathrm{tr}(\mathbf{y}^\top\mathbf{x}) = \mathbf{y}^\top\mathbf{x} \in \mathbb{R} \tag{4.20}$$

선형 사상의 기저 독립성

선형 사상 $\Phi : V \to V$가 주어졌을 때, 임의의 기저 하에서 이 사상을 표현하는 변환 행렬을 A라 합시다. 다른 기저를 선택했을 때의 변환 행렬을 B라 하면 기저 변환 공식에 의해 적절한 가역 행렬 S에 대해 $B = S^{-1}AS$가 성립합니다. 이때 B의 대각합은 다음과 같습니다.

$$\mathrm{tr}(B) = \mathrm{tr}(S^{-1}AS) \overset{(4.19)}{=} \mathrm{tr}(ASS^{-1}) = \mathrm{tr}(A\mathbf{I}) = \mathrm{tr}(A) \tag{4.21}$$

따라서, **선형 사상의 대각합은 기저의 선택에 무관하게 항상 일정하게 유지되는 기저 독립적(basis independent)인 고유한 특성 물리량**입니다.

4.1.3 특성 다항식 (Characteristic Polynomial)

행렬식과 대각합을 결합하여, 정사각 행렬 $A \in \mathbb{R}^{n\times n}$의 핵심 대수적 성질을 변수 λ에 대한 다항식 형태로 기술한 것을 **특성 다항식**이라 정의합니다.

[정의 4.5] 특성 다항식 (Characteristic Polynomial)

스칼라 변수 $\lambda \in \mathbb{R}$와 정사각 행렬 $A \in \mathbb{R}^{n\times n}$에 대하여,

$$p_A(\lambda) := \det(A - \lambda\mathbf{I}) \tag{4.22a}$$

를 행렬 A의 **특성 다항식**이라 합니다. 이를 전개하면 다음과 같은 n차 다항식의 형태를 띕니다.

$$p_A(\lambda) = c_0 + c_1\lambda + c_2\lambda^2 + \cdots + c_{n-1}\lambda^{n-1} + (-1)^n\lambda^n \tag{4.22b}$$

이때 최고차항과 최저차항 등 주요 계수들은 다음과 같은 성질을 갖습니다.

$$c_0 = \det(A) \tag{4.23}$$

$$c_{n-1} = (-1)^{n-1}\mathrm{tr}(A) \tag{4.24}$$

이 특성 다항식의 해를 구함으로써 우리는 고유값과 고유벡터를 도출하게 됩니다.

4.2 고유값과 고유벡터 (Eigenvalues and Eigenvectors)

선형 변환 Φ를 표현하는 행렬 $A \in \mathbb{R}^{n\times n}$를 곱했을 때, 방향은 변하지 않고 오직 크기만 실수배로 늘어나거나 줄어드는 특별한 벡터들이 존재합니다. 이 특수한 벡터들을 **고유벡터**, 변환 배율을 **고유값**이라 부릅니다.

[정의 4.6] 고유값과 고유벡터

정사각 행렬 $A \in \mathbb{R}^{n\times n}$에 대하여, 영벡터가 아닌 임의의 벡터 $\mathbf{x} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$와 스칼라 $\lambda \in \mathbb{R}$가 다음 방정식을 만족할 때, **λ를 행렬 A의 고유값(Eigenvalue)**이라 하고, **$\mathbf{x}$를 λ에 대응하는 고유벡터(Eigenvector)**라고 정의합니다.

$$A\mathbf{x} = \lambda\mathbf{x} \tag{4.25}$$

위 방정식을 **고유값 방정식(Eigenvalue Equation)**이라 부릅니다.

> [!NOTE] 'Eigen'은 '특유의', '독자적인'을 뜻하는 독일어 형용사에서 유래하였습니다. 고유값과 고유벡터는 선형 사상이 벡터 공간 내의 특정 축들을 어떻게 스케일링하는지 보여주는 사상 고유의 뼈대 정보를 담고 있습니다.

고유값의 동치 조건들

다음 문장들은 수학적으로 완전히 동치(Equivalent)입니다.

1. λ는 행렬 $A \in \mathbb{R}^{n\times n}$의 고유값이다.
2. $A\mathbf{x} = \lambda\mathbf{x}$를 만족하는 비영벡터 $\mathbf{x} \neq \mathbf{0}$가 존재한다. 즉, 동차선형연립방정식 $(A - \lambda\mathbf{I})\mathbf{x} = \mathbf{0}$이 자명하지 않은 해(Non-trivial solution)를 갖는다.
3. 행렬 $A - \lambda\mathbf{I}$의 랭크가 완전하지 않다: $\mathrm{rk}(A - \lambda\mathbf{I}) < n$
4. 행렬 $A - \lambda\mathbf{I}$의 행렬식이 0이다: $\det(A - \lambda\mathbf{I}) = 0$

[정의 4.7] 공선성과 공향성

- **공향성 (Codirection)**: 두 벡터가 완벽하게 가리키는 방향이 같을 때 이를 공향 벡터라고 합니다.
- **공선성 (Collinearity)**: 두 벡터가 가리키는 방향이 같거나 또는 정반대(일직선상에 정렬)일 때 이를 공선 벡터라고 합니다.

고유벡터의 비유일성 (방향의 대표성)

만약 벡터 $\mathbf{x}$가 고유값 λ에 대응하는 A의 고유벡터라면, 0이 아닌 임의의 스칼라 $c \in \mathbb{R} \setminus \{0\}$배를 해 준 $c\mathbf{x}$ 역시 동일한 고유값 λ를 공유하는 고유벡터가 됩니다.

$$A(c\mathbf{x}) = c(A\mathbf{x}) = c(\lambda\mathbf{x}) = \lambda(c\mathbf{x}) \tag{4.26}$$

따라서 고유벡터는 단일 벡터로 유일하게 결정되는 것이 아니라, 특정 **직선 방향(Line)** 전체가 고유벡터의 성질을 공유합니다. 일반적으로는 크기가 1인 단위벡터 형태로 정규화하여 대표 벡터로 사용합니다.

[정리 4.8] 특성 다항식의 근으로서의 고유값

$\lambda \in \mathbb{R}$가 행렬 $A \in \mathbb{R}^{n \times n}$의 고유값이 될 필요충분조건은 λ가 특성 다항식 $p_A(\lambda) = \det(A - \lambda \mathbf{I}) = 0$의 근(Root)이 되는 것입니다.

[정의 4.9] 대수적 중복도 (Algebraic Multiplicity)

행렬 A의 특성 다항식을 인수분해하였을 때, 특정 고유값 λ_i에 해당하는 인수 $(\lambda - \lambda_i)$가 곱해진 거듭제곱 횟수 m을 해당 고유값의 **대수적 중복도**라고 정의합니다.

[정의 4.10] 고유공간 (Eigenspace)과 고유 스펙트럼 (Eigenspectrum)

- **고유공간 (Eigenspace)**: 특정 고유값 λ에 대응하는 모든 고유벡터들과 영벡터 $\mathbf{0}$를 모은 집합은 $\mathbb{R}^n$의 부분공간을 형성하며, 이를 고유공간 E_λ라고 합니다.

$$E_\lambda = \ker(A - \lambda \mathbf{I}) \tag{4.27b}$$

- **고유 스펙트럼 (Eigenspectrum / Spectrum)**: 행렬 A가 가지는 모든 고유값들의 집합을 의미합니다.

[예제 4.5] 고유값, 고유벡터, 고유공간 계산

다음 2×2 행렬 A의 고유값과 고유벡터를 계산합니다.

$$A = \begin{bmatrix} 4 & 2 \\ 1 & 3 \end{bmatrix} \tag{4.28}$$

1. **특성 다항식 도출**:

$$\det(A - \lambda \mathbf{I}) = \begin{vmatrix} 4-\lambda & 2 \\ 1 & 3-\lambda \end{vmatrix} = (4-\lambda)(3-\lambda) - 2 \cdot 1 = \lambda^2 - 7\lambda + 10 \tag{4.29}$$

2. **고유값 계산**: 특성 다항식을 인수분해합니다.

$$p_A(\lambda) = (\lambda - 2)(\lambda - 5) = 0 \tag{4.30}$$

   따라서 서로 다른 두 근 $\lambda_1 = 2$, $\lambda_2 = 5$를 고유값으로 가집니다.

3. $\lambda = 5$**에 대응하는 고유공간 계산**:

$$(A - 5\mathbf{I})\mathbf{x} = \begin{bmatrix} -1 & 2 \\ 1 & -2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \tag{4.32}$$

   방정식을 풀면 $x_1 = 2x_2$가 도출되므로, 고유공간 E_5는 다음과 같이 1차원 부분공간이 됩니다.

$$E_5 = \text{span}\left(\begin{bmatrix} 2 \\ 1 \end{bmatrix} \right) \tag{4.33}$$

4. $\lambda = 2$**에 대응하는 고유공간 계산**:

$$(A - 2\mathbf{I})\mathbf{x} = \begin{bmatrix} 2 & 2 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \tag{4.34}$$

   방정식을 풀면 $x_2 = -x_1$이 도출되므로, 고유공간 E_2는 다음과 같이 1차원 부분공간이 됩니다.

$$E_2 = \text{span}\left(\begin{bmatrix} 1 \\ -1 \end{bmatrix}\right) \tag{4.35}$$

[정의 4.11] 기하적 중복도 (Geometric Multiplicity)

특정 고유값 λ_i에 대응하는 고유공간 E_{λ_i}의 차원(Dimension)을 해당 고유값의 **기하적 중복도**라고 정의합니다. 즉, 고유값 λ_i에 대응하는 선형 독립인 고유벡터의 최대 개수입니다.

> [!IMPORTANT] 임의의 고유값의 기하적 중복도는 **최소 1 이상**이어야 하며, 해당 고유값의 **대수적 중복도를 절대로 초과할 수 없습니다.**
>
> $$\text{Geometric Multiplicity}(\lambda_i) \leq \text{Algebraic Multiplicity}(\lambda_i)$$

[예제 4.6] 대수적 중복도와 기하적 중복도가 일치하지 않는 경우

다음 행렬 A가 주어졌을 때,

$$A = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix}$$

특성 다항식은 $p_A(\lambda) = (2-\lambda)^2 = 0$이므로 고유값은 $\lambda = 2$ 단 하나이며 대수적 중복도는 2입니다. 그러나 고유벡터를 찾기 위해 $(A - 2\mathbf{I})\mathbf{x} = \mathbf{0}$을 전개하면 다음과 같습니다.

$$\begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \implies x_2 = 0$$

이때 자유 변수는 x_1 하나뿐이므로, 고유벡터는 $\begin{bmatrix} 1 \\ 0 \end{bmatrix}$ 스칼라배 형태만 존재합니다. 즉, 고유공간 E_2의 차원(기하적 중복도)은 1입니다. 이와 같이 대수적 중복도보다 기하적 중복도가 작은 행렬이 존재합니다.

[시각 자료] 2차원 공간에서의 선형 변환별 고유 스펙트럼 기하 예시 (Figure 4.4)

2차원 격자점들에 상이한 변환 행렬 A_i를 가했을 때 기하학적으로 일어나는 변화와 고유 스펙트럼 상태입니다.

1. **스케일링 변환** ($A_1 = \begin{bmatrix} 0.5 & 0 \\ 0 & 2 \end{bmatrix}$, $\det = 1.0$):
   - 고유값: $\lambda_1 = 2.0$ (세로 방향 두 배 인장), $\lambda_2 = 0.5$ (가로 방향 반으로 압축).
   - 고유벡터는 표준 축 방향 $\mathbf{e}_1, \mathbf{e}_2$로 직교 유지. 면적 보존.
2. **전단 변환 (Shearing)** ($A_2 = \begin{bmatrix} 1 & 0.5 \\ 0 & 1 \end{bmatrix}$, $\det = 1.0$):
   - 고유값: $\lambda_1 = 1.0$ (대수적 중복도 2, 기하적 중복도 1).
   - 고유벡터들이 가로축 방향 $\begin{bmatrix} 1 \\ 0 \end{bmatrix}$ 일직선상으로 찌그러짐(공선 벡터화).
3. **회전 변환 (Rotation)** ($A_3 = \begin{bmatrix} \cos(\pi/6) & -\sin(\pi/6) \\ \sin(\pi/6) & \cos(\pi/6) \end{bmatrix}$, $\det = 1.0$):
   - 고유값: 복소수 $\lambda_{1,2} = 0.87 \pm 0.5j$.
   - 실수 공간 상에는 고유벡터가 존재하지 않으므로 어떠한 선형 독립 축도 제자리를 지키지 못하고 회전합니다.
4. **차원 붕괴 변환 (Collapse)** ($A_4 = \begin{bmatrix} 1 & -1 \\ -1 & 1 \end{bmatrix}$, $\det = 0.0$):

- 고유값: $\lambda_1 = 0$ (방향 붕괴), $\lambda_2 = 2.0$ (수직축 방향 확대).
- 2차원 평면이 1차원 직선 공간으로 짓눌려 투영되므로 면적이 0이 됩니다.

5. **전단 및 스케일링 복합 변환** ($A_5 = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \end{bmatrix}$, $\det = 0.75$):
   - 고유값: $\lambda_1 = 0.5$, $\lambda_2 = 1.5$.
   - 공간을 대칭적으로 늘리고 줄여 면적을 원래의 75% 크기로 축소시킵니다.

[예제 4.7] 생물학적 신경망의 고유 스펙트럼 분석

머신러닝과 데이터 과학에서 네트워크 노드 간의 연결 구조를 분석하는 데 고유값 분석이 널리 쓰입니다. 선충류 생물인 예쁜꼬마선충(C. Elegans)의 뇌는 총 277개의 뉴런으로 구성되어 있습니다. 이들의 연결 정보를 나타내는 인접 행렬 $A \in \mathbb{R}^{277 \times 277}$은 비대칭 행렬이므로 복소수 고유값을 갖습니다. 방향성을 지우고 뉴런 간 연결 여부만 고려하기 위해 대칭화된 연결 행렬 $A_{\text{sym}} := A + A^\top$을 만듭니다. 이 대칭 행렬의 고유값들을 정렬하여 시각화한 **고유 스펙트럼(Eigenspectrum)**은 특유의 S자 곡선을 띕니다. 이는 수많은 뇌 세포 신경망이 가진 위상학적 성질을 행렬의 고유값 분포로 집약하여 보여주는 대표적인 신경과학 분석 도구입니다.

[정리 4.12] 고유벡터의 선형 독립성

서로 다른 n개의 고유값 $\lambda_1, \dots, \lambda_n$을 가지는 정사각 행렬 $A \in \mathbb{R}^{n \times n}$의 대응 고유벡터 $\mathbf{x}_1, \dots, \mathbf{x}_n$은 **서로 선형 독립**입니다. 따라서, n개의 서로 다른 고유값을 갖는 행렬의 고유벡터들은 벡터 공간 $\mathbb{R}^n$의 기저(Basis)를 형성하게 됩니다.

[정의 4.13] 결함 행렬 (Defective Matrix)

정사각 행렬 $A \in \mathbb{R}^{n \times n}$이 선형 독립인 고유벡터를 n개보다 적게 가질 때, 이 행렬을 **결함 행렬**이라고 합니다. 결함 행렬은 적어도 하나 이상의 고유값의 기하적 중복도가 대수적 중복도보다 엄격히 작으며, 고유벡터들로 $\mathbb{R}^n$의 기저를 구성하는 것이 불가능합니다.

대칭행렬과 고유값의 특별한 관계

실수 대칭 행렬 $S = S^\top$은 수학적으로 매우 유용한 고유값 성질을 가집니다.

[정리 4.14] 임의의 행렬을 통한 대칭 반정치 행렬의 빌드

임의의 행렬 $A \in \mathbb{R}^{m \times n}$에 대하여, $S := A^\top A \in \mathbb{R}^{n \times n}$로 정의된 행렬은 항상 **대칭(Symmetric) 행렬**이며 **양의 반정치(Positive semidefinite) 행렬**입니다.

> [!NOTE]
>
> - **대칭성 증명**: $S^\top = (A^\top A)^\top = A^\top (A^\top)^\top = A^\top A = S$
> - **양의 반정치성 증명**: 임의의 $\mathbf{x} \in \mathbb{R}^n$에 대하여, $\mathbf{x}^\top S \mathbf{x} = \mathbf{x}^\top A^\top A \mathbf{x} = (A\mathbf{x})^\top (A\mathbf{x}) = \|A\mathbf{x}\|_2^2 \geq 0$. 만약 A의 랭크가 n이라면 S는 양의 정치(Positive definite) 행렬이 되어 임의의 비영벡터 $\mathbf{x} \neq \mathbf{0}$에 대해 $\mathbf{x}^\top S \mathbf{x} > 0$이 항상 성립합니다.

[정리 4.15] 스펙트럼 정리 (Spectral Theorem)

실수 대칭 행렬 $A \in \mathbb{R}^{n \times n}$에 대하여 다음 두 성질이 항상 보장됩니다.

1. A의 모든 고유값은 항상 **실수(Real number)**입니다.
2. A의 고유벡터들로 구성된 $\mathbb{R}^n$의 **정규직교기저(Orthonormal Basis)**가 항상 존재합니다.

따라서 대칭행렬 A는 항상 고유벡터들의 직교행렬 P와 대각선 성분이 고유값으로 이루어진 대각행렬 D에 대해 $A = PDP^\top$ 형태로 고유값 분해가 가능합니다.

[예제 4.8] 대칭행렬 고유벡터의 정규직교화 과정

다음과 같은 실수 대칭 행렬 A가 주어져 있습니다.

$$A = \begin{bmatrix} 3 & 2 & 2 \\ 2 & 3 & 2 \\ 2 & 2 & 3 \end{bmatrix} \tag{4.37}$$

이 행렬의 특성 다항식은 다음과 같이 유도됩니다.

$$p_A(\lambda) = -(\lambda - 1)^2(\lambda - 7) = 0 \tag{4.38}$$

고유값은 중복도가 2인 $\lambda_1 = 1$과 단일근인 $\lambda_2 = 7$입니다. 각 고유값에 대응하는 고유공간을 구하면 다음과 같습니다.

$$E_1 = \text{span}\left(\underbrace{\begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}}_{\mathbf{x}_1}, \underbrace{\begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix}}_{\mathbf{x}_2} \right), \quad E_7 = \text{span}\left(\underbrace{\begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}}_{\mathbf{x}_3} \right) \tag{4.39}$$

$\mathbf{x}_3$는 $\mathbf{x}_1$ 및 $\mathbf{x}_2$와 내적을 해 보면 직교함($\mathbf{x}_1^\top \mathbf{x}_3 = 0, \mathbf{x}_2^\top \mathbf{x}_3 = 0$)을 확인할 수 있습니다. 그러나 동일한 고유값공간 E_1 내에 있는 두 기저 벡터 $\mathbf{x}_1$과 $\mathbf{x}_2$는 직교하지 않습니다 ($\mathbf{x}_1^\top \mathbf{x}_2 = 1 \neq 0$). 스펙트럼 정리가 보장하는 정규직교기저를 완성하기 위해서는 같은 고유공간 내부의 벡터들을 직교화해 주어야 합니다.

동일한 고유공간 내의 모든 선형 결합 역시 고유벡터임을 이용하여, **그람-슈미트 직교화 알고리즘**을 E_1의 기저 벡터인 $\mathbf{x}_1, \mathbf{x}_2$에 적용합니다.

1. 첫 번째 직교 벡터 $\mathbf{x}_1'$ 지정:

$$\mathbf{x}_1' = \mathbf{x}_1 = \begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}$$

2. 두 번째 성분에서 사영 성분 차감하여 $\mathbf{x}_2'$ 계산:

$$\mathbf{x}_2' = \mathbf{x}_2 - \frac{\mathbf{x}_2^\top \mathbf{x}_1'}{\|\mathbf{x}_1'\|_2^2}\mathbf{x}_1' = \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix} - \frac{1}{2}\begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix} = \begin{bmatrix} -0.5 \\ -0.5 \\ 1 \end{bmatrix} \propto \begin{bmatrix} -1 \\ -1 \\ 2 \end{bmatrix}$$

상수배 정리를 통해 얻은 최종 직교화 고유벡터 쌍은 다음과 같으며, 이들은 서로 직교하고 $\mathbf{x}_3$와도 완벽한 수직 관계를 이룹니다.

$$\mathbf{x}_1' = \begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{x}_2' = \begin{bmatrix} -1 \\ -1 \\ 2 \end{bmatrix} \tag{4.41}$$

고유값과 행렬식·대각합의 대수/기하적 관계

정사각 행렬 $A \in \mathbb{R}^{n \times n}$이 가지는 고유값 $\lambda_1, \ldots, \lambda_n$ (중복도 포함 및 복소근 포함)에 대해 다음 정리들이 성립합니다.

[정리 4.16] 행렬식과 고유값의 관계

행렬식은 모든 고유값들의 **곱**과 같습니다.

$$\det(A) = \prod_{i=1}^{n} \lambda_i \tag{4.42}$$

[정리 4.17] 대각합과 고유값의 관계

대각합은 모든 고유값들의 **합**과 같습니다.

$$\mathrm{tr}(A) = \sum_{i=1}^{n} \lambda_i \tag{4.43}$$

[시각 자료] 고유값의 기하학적 면적/둘레 변환 효과 (Figure 4.6)

정규직교 고유벡터 기저 $(\mathbf{x}_1, \mathbf{x}_2)$로 이루어진 2차원 평면의 단위 정사각형이 사상 A에 의해 변환될 때 기하학적 외곽 형상의 변화율입니다.

- **면적의 변화**: 각 고유벡터 축이 고유값 크기 λ_1, λ_2만큼 스케일링되므로, 변환된 사각형의 면적은 원래 넓이(1)에서 고유값의 곱인 $|\lambda_1 \lambda_2|$배로 바뀝니다 ($\det(A)$의 물리적 의미와 일치).
- **둘레의 변화**: 원래 정사각형의 둘레는 $2(1+1) = 4$입니다. 변환 후의 직사각형 둘레는 $2(|\lambda_1| + |\lambda_2|)$가 되므로, 고유값의 절대값 합이 둘레의 변화율을 결정짓습니다.

[예제 4.9] 구글의 페이지랭크 (Google PageRank)

초기 구글의 검색 엔진을 정립한 페이지랭크 알고리즘은 거대한 웹페이지 링크 관계를 유향 그래프로 표현하고, 이에 따른 전이 확률 행렬(Transition Matrix) A를 작성합니다. 임의의 웹 사용자가 링크를 무작위로 클릭하여 도달하는 최종 상태의 페이지 확률 분포 벡터 $\mathbf{x}^*$는 시간이 지남에 따라 변하지 않는 상태에 도달합니다. 즉, $A\mathbf{x}^* = \mathbf{x}^*$를 만족합니다. 이는 **고유값이 1인 전이 행렬의 고유벡터**를 찾는 문제와 정확히 동일합니다. 구글은 이 주 고유벡터(Principal Eigenvector)의 성분 크기를 바탕으로 각 웹페이지의 상대적 중요도 등급을 평가하였습니다.

4.3 숄레스키 분해 (Cholesky Decomposition)

양의 실수 영역에서 임의의 수를 동일한 수의 제곱근 곱(예: $9 = 3 \times 3$)으로 쪼개는 것과 유사하게, 행렬 연산에서도 대칭 양의 정치 행렬을 대상으로 제곱근에 해당하는 삼각행렬로 분해하는 기법이 존재하는데, 이를 **숄레스키 분해**라고 합니다.

[정리 4.18] 숄레스키 분해 (Cholesky Decomposition)

임의의 대칭 양의 정치(Symmetric, positive-definite) 행렬 $A \in \mathbb{R}^{n \times n}$는 **하삼각행렬 L과 그의 전치행렬 $L^\top$의 곱**으로 유일하게 분해됩니다.

$$A = LL^\top \tag{4.44}$$

여기서 L은 주대각선 성분이 모두 양의 실수인 하삼각행렬이며, 이를 **숄레스키 인자(Cholesky Factor)**라고 부릅니다.

$$\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix} = \begin{bmatrix} l_{11} & \cdots & 0 \\ \vdots & \ddots & \vdots \\ l_{n1} & \cdots & l_{nn} \end{bmatrix} \begin{bmatrix} l_{11} & \cdots & l_{n1} \\ \vdots & \ddots & \vdots \\ 0 & \cdots & l_{nn} \end{bmatrix}$$

[예제 4.10] 3×3 행렬의 숄레스키 분해 공식 유도

대칭 양의 정치 행렬 $A \in \mathbb{R}^{3 \times 3}$에 대해 분해 식 $A = LL^\top$을 대수적으로 직접 계산해 보겠습니다.

$$\begin{bmatrix} a_{11} & a_{21} & a_{31} \\ a_{21} & a_{22} & a_{32} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} = \begin{bmatrix} l_{11} & 0 & 0 \\ l_{21} & l_{22} & 0 \\ l_{31} & l_{32} & l_{33} \end{bmatrix} \begin{bmatrix} l_{11} & l_{21} & l_{31} \\ 0 & l_{22} & l_{32} \\ 0 & 0 & l_{33} \end{bmatrix} \tag{4.45}$$

오른쪽 행렬 곱을 연산하면 다음과 같습니다.

$$LL^\top = \begin{bmatrix} l_{11}^2 & l_{21}l_{11} & l_{31}l_{11} \\ l_{21}l_{11} & l_{21}^2 + l_{22}^2 & l_{31}l_{21} + l_{32}l_{22} \\ l_{31}l_{11} & l_{31}l_{21} + l_{32}l_{22} & l_{31}^2 + l_{32}^2 + l_{33}^2 \end{bmatrix} \tag{4.46}$$

좌변과 우변의 각 원소를 일대일 비교하여 삼각행렬 L의 대각 원소 l_{ii}들을 다음과 같이 순차적으로 유도해낼 수 있습니다.

$$l_{11} = \sqrt{a_{11}}, \quad l_{22} = \sqrt{a_{22} - l_{21}^2}, \quad l_{33} = \sqrt{a_{33} - (l_{31}^2 + l_{32}^2)} \tag{4.47}$$

마찬가지로 대각 아래 원소 l_{ij} $(i > j)$들도 유도됩니다.

$$l_{21} = \frac{a_{21}}{l_{11}}, \quad l_{31} = \frac{a_{31}}{l_{11}}, \quad l_{32} = \frac{a_{32} - l_{31}l_{21}}{l_{22}} \tag{4.48}$$

이와 같이 이미 계산된 앞 단계의 l_{ij} 값들을 재사용하여 역으로 거슬러 계산해 나가는 방식으로 하삼각행렬의 모든 계수를 유일하게 결정할 수 있습니다.

머신러닝에서의 숄레스키 분해의 중요성 및 응용

- **가우시안 샘플링**: 평균이 μ이고 공분산 행렬이 $\mathbf{\Sigma}$인 다변량 가우시안 변수 $\mathbf{x} \sim \mathcal{N}(\mu, \mathbf{\Sigma})$를 컴퓨터 상에서 직접 난수로 생성하려 할 때, 공분산 행렬의 숄레스키 분해 $\mathbf{\Sigma} = LL^\top$가 결정적인 역할을 수행합니다. 표준 정규분포 난수 벡터 $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$에 변환을 가해 $\mathbf{x} = \mu + L\mathbf{z}$를 생성할 수 있습니다.
- **재매개변수화 트릭 (Reparameterization Trick)**: 딥러닝 확률 모델인 변이형 오토인코더(VAE) 등에서 확률적 오차를 유지하면서 역전파(Backpropagation) 기울기를 미분 가능하게 흘려보내기 위해 이 숄레스키 변환 구조를 사용합니다.
- **효율적인 행렬식 계산**: 가역 대칭 행렬 A의 행렬식을 직접 구하는 대신 숄레스키 분해를 수행하면 다음과 같이 계산 효율이 극대화됩니다.

$$\det(A) = \det(LL^\top) = \det(L)\det(L^\top) = \det(L)^2 = \left(\prod_i l_{ii}\right)^2 = \prod_i l_{ii}^2$$

하삼각행렬의 행렬식은 주대각선 성분의 곱에 불과하므로 복잡한 행렬식 연산이 단순 스칼라들의 곱셈 연산으로 치환됩니다.

4.4 고유값 분해와 대각화 (Eigendecomposition and Diagonalization)

대각행렬 D는 역행렬 계산(d_{ii}의 역수), 거듭제곱($D^k = \mathrm{diag}(d_{ii}^k)$), 행렬식 계산($d_{ii}$들의 곱) 측면에서 엄청난 컴퓨터 수치 계산상의 강점을 갖습니다. 일반 행렬의 곱 변환을 이러한 축방향 독립 스케일링으로 단순화하기 위해 기저 변환을 결합하는 과정을 **대각화**라고 합니다.

[정의 4.19] 대각화 가능성 (Diagonalizable)

행렬 $A \in \mathbb{R}^{n\times n}$에 대하여, 어떤 가역 행렬 $P \in \mathbb{R}^{n\times n}$가 존재하여 $P^{-1}AP = D$ 형태의 대각행렬로 만들 수 있을 때, 이 행렬 A를 **대각화 가능**하다고 정의합니다.

닮음 변환 행렬 P를 열벡터들로 분할하여 $P = [\mathbf{p}_1, \dots, \mathbf{p}_n]$이라 하고, 대각행렬 $D = \mathrm{diag}(\lambda_1, \dots, \lambda_n)$이라 두었을 때,

$$AP = PD \tag{4.50}$$

의 행렬 곱을 직접 전개하면 다음과 같습니다.

$$A[\mathbf{p}_1, \dots, \mathbf{p}_n] = [A\mathbf{p}_1, \dots, A\mathbf{p}_n] \tag{4.51}$$

$$[\mathbf{p}_1, \dots, \mathbf{p}_n]\mathrm{diag}(\lambda_1, \dots, \lambda_n) = [\lambda_1\mathbf{p}_1, \dots, \lambda_n\mathbf{p}_n] \tag{4.52}$$

따라서 $AP = PD$가 성립하려면 모든 열벡터 축에 대해 다음 관계가 정확하게 만족되어야 합니다.

$$A\mathbf{p}_i = \lambda_i \mathbf{p}_i, \quad i = 1, \dots, n \tag{4.53-4.54}$$

이는 P의 열벡터 $\mathbf{p}_i$가 행렬 A의 고유벡터들이고, D의 대각 원소 λ_i가 이에 대응하는 고유값들이어야 함을 의미합니다.

[정리 4.20] 고유값 분해 (Eigendecomposition)

정사각 행렬 $A \in \mathbb{R}^{n\times n}$가 $A = PDP^{-1}$**로 인수분해(고유값 분해)될 필요충분조건은** A**의 고유벡터들이** $\mathbb{R}^n$**의 기저를 형성(즉,** n**개의 선형 독립 고유벡터를 보유)하는 것입니다.**

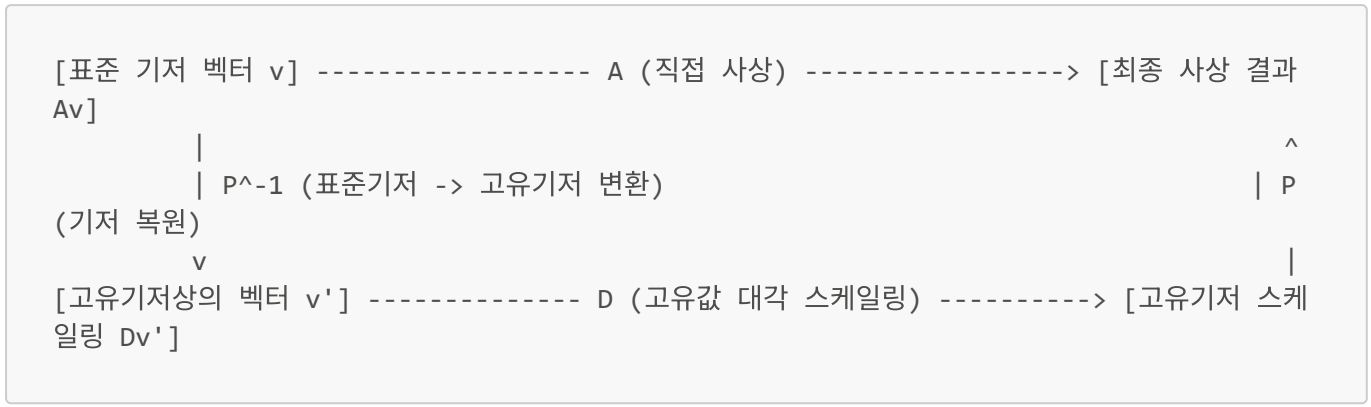
[정리 4.21] 대칭행렬의 대각화 보장

모든 실수 대칭행렬 $S = S^\top \in \mathbb{R}^{n\times n}$은 고유벡터들이 언제나 정규직교기저를 형성하므로 가역행렬 P가 직교행렬 $P^\top = P^{-1}$이 되어 **항상 직교 대각화가 가능**합니다.

$$S = PDP^\top$$

[시각 자료] 고유값 분해의 기하학적 단계별 사상 흐름 (Figure 4.7)

임의의 사상 A를 고유값 분해 단계로 쪼개어 이해하는 기하 흐름도입니다.



1. P^{-1} **단계**: 표준 기저 하의 입력 벡터 $\mathbf{v}$를 고유벡터들이 이루는 새로운 기저 좌표계(Eigenbasis)로 회전 및 변환하여 $\mathbf{v}'$를 얻습니다.
2. D **단계**: 고유기저 축 방향으로 각 성분을 고유값 λ_i 비율만큼 독립적으로 확장 혹은 축소하여 $D\mathbf{v}'$를 도출합니다 (원형의 점들이 타원 형태로 찌그러집니다).
3. P **단계**: 타원형으로 스케일링이 완료된 벡터들을 다시 원래의 표준 좌표계로 역변환하여 최종 사상 결과 $A\mathbf{v}$를 도출합니다.

[예제 4.11] 고유값 분해의 대수적 전개

다음 행렬 A의 고유값 분해를 수행합니다.

$$A = \frac{1}{2}\begin{bmatrix} 5 & -2 \\ -2 & 5 \end{bmatrix} \tag{4.61-A}$$

1. **고유값 계산**:

$$\det(A - \lambda \mathbf{I}) = \left(\frac{5}{2} - \lambda\right)^2 - 1 = \lambda^2 - 5\lambda + \frac{21}{4} = \left(\lambda - \frac{7}{2}\right)\left(\lambda - \frac{3}{2}\right) = 0 \tag{4.56}$$

   고유값은 $\lambda_1 = \frac{7}{2}, \lambda_2 = \frac{3}{2}$입니다.
2. **단위 고유벡터 유도**:

$$\mathbf{p}_1 = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ -1 \end{bmatrix}, \quad \mathbf{p}_2 = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 \\ 1 \end{bmatrix} \tag{4.58}$$

   고유벡터 $\mathbf{p}_1$과 $\mathbf{p}_2$는 서로 독립이므로 대각화가 보장됩니다.
3. **대각화 변환 행렬 조립**:

$$P = [\mathbf{p}_1, \mathbf{p}_2] = \frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix} \tag{4.59}$$

   고유벡터들이 직교하므로 $P^{-1} = P^{\top}$입니다. 최종 분해를 수행하면 다음과 같습니다.

$$A = PDP^{-1} = \left(\frac{1}{\sqrt{2}}\begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix}\right)\begin{bmatrix} 7/2 & 0 \\ 0 & 3/2 \end{bmatrix}\left(\frac{1}{\sqrt{2}}\begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}\right) \tag{4.61}$$

행렬의 거듭제곱 가속화

고유값 분해를 얻게 되면, 행렬을 k번 연속으로 곱해야 하는 엄청난 계산량의 수치 연산이 다음과 같이 최적화됩니다.

$$A^k = (PDP^{-1})^k = PD^kP^{-1} \tag{4.62}$$

대각행렬 D의 거듭제곱은 각 대각성분 d_{ii}에만 k제곱을 가하면 되므로 거듭제곱 연산이 순식간에 이루어집니다.

4.5 특이값 분해 (Singular Value Decomposition - SVD)

고유값 분해는 오직 특정 대각화 조건을 충족하는 정사각 행렬에서만 사용할 수 있는 한계가 있습니다. 이러한 한계를 넘어 **어떠한 형태의 임의의 직사각 행렬 $A \in \mathbb{R}^{m \times n}$에 대해서도 항상 존재하고 적용할 수 있는 강력한 일반화 행렬 분해 기법**이 바로 **특이값 분해 (SVD)**입니다.

[정리 4.22] SVD 정리 (SVD Theorem)

임의의 랭크 $r \in [0, \min(m, n)]$를 갖는 실수 직사각 행렬 $A \in \mathbb{R}^{m \times n}$는 다음과 같이 세 행렬의 곱으로 항상 분해될 수 있습니다.

$$A = U\Sigma V^\top \tag{4.64}$$

- $U \in \mathbb{R}^{m \times m}$: 공역 공간 $\mathbb{R}^m$의 정규직교기저를 형성하는 **직교 행렬**입니다. 이 열벡터 $\mathbf{u}_i$들을 **좌특이벡터 (Left-singular vectors)**라고 부릅니다.
- $V \in \mathbb{R}^{n \times n}$: 정의역 공간 $\mathbb{R}^n$의 정규직교기저를 형성하는 **직교 행렬**입니다. 이 열벡터 $\mathbf{v}_j$들을 **우특이벡터 (Right-singular vectors)**라고 부릅니다.
- $\Sigma \in \mathbb{R}^{m \times n}$: A와 크기가 같은 행렬로, 대각선 이외의 모든 성분은 0이며 주대각선 성분으로 비음(Non-negative)의 실수값 σ_i를 내림차순 정렬하여 갖습니다 ($\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r \geq 0$). 이 σ_i들을 **특이값 (Singular values)**이라고 부릅니다.

특이값 행렬 Σ의 크기별 제로 패딩 구조

Σ는 정사각 행렬이 아닌 직사각 행렬이므로 잔여 행/열 부분을 0으로 채워 행렬의 형태를 맞춰야 합니다.

- $m > n$ **인 경우 (세로가 더 긴 행렬)**: n행까지 대각선에 특이값이 들어가고 아래쪽은 행벡터 $\mathbf{0}^\top$들로 채워집니다.

$$\Sigma = \begin{bmatrix} \sigma_1 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \sigma_n \\ 0 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 0 \end{bmatrix} \in \mathbb{R}^{m \times n} \tag{4.65}$$

- $m < n$ **인 경우 (가로가 더 긴 행렬)**: m열까지 대각선에 특이값이 들어가고 우측은 열벡터 $\mathbf{0}$들로 채워집니다.

$$\Sigma = \begin{bmatrix} \sigma_1 & 0 & 0 & 0 & \cdots & 0 \\ 0 & \ddots & 0 & \vdots & \ddots & \vdots \\ 0 & 0 & \sigma_m & 0 & \cdots & 0 \end{bmatrix} \in \mathbb{R}^{m \times n} \tag{4.66}$$

4.5.1 SVD의 기하학적 직관 (Figure 4.8 & 4.9)

고유값 분해는 입력과 출력이 동일한 차원의 동일한 좌표계 상에서 기저 변환이 가해지는 반면, SVD는 정의역 $\mathbb{R}^n$과 공역 $\mathbb{R}^m$이라는 전혀 다른 두 공간 사이의 기하학적 매핑 관계를 보여줍니다.

```
[정의역 R^n의 기저 B~ (v1, v2)] -------- V^T (정의역 기저 변환) ------> [정의역 R^n의 표준 기저 B]
                                                                                    |
                                                                                    |
Σ (차원 매핑 & 스케일링)
                                                                                    v
[공역 R^m의 표준 기저 C] <------------- U (공역 기저 변환) ------------ [공역 R^m의 기저 C~ (u1, u2, u3)]
```

1. $V^\top$ **단계**: 정의역 $\mathbb{R}^n$ 상의 일반적인 직교 좌표축 벡터들을 회전(Rotation) 변환시켜, 입력 다차원 평면이 정렬될 축 방향인 우특이벡터 기저계로 좌표계를 변환합니다.
2. Σ **단계**: 변환된 기저 방향으로 각 벡터의 크기를 특이값 σ_i 비율로 독립 스케일링하며, 남는 차원을 추가하거나 버림으로써 차원 전이($\mathbb{R}^n \to \mathbb{R}^m$)를 수행합니다. (예: 2차원의 원판 모양 영역이 3차원 공간 속의 타원판 형상으로 매핑됩니다.)
3. U **단계**: 공역 $\mathbb{R}^m$으로 넘어온 스케일링 벡터들을 다시 공역 표준 좌표계 방향에 맞도록 최종 회전시킵니다.

4.5.2 SVD의 대수적 구축 및 증명 과정

임의의 행렬 $A \in \mathbb{R}^{m \times n}$에 대해 SVD 공식 $A = U\Sigma V^\top$가 항상 성립하고 계산될 수 있는 유도 과정은 다음과 같습니다.

1단계: 우특이벡터 V 구축

정리 4.14에 의해 대칭 반정치 행렬 $A^\top A \in \mathbb{R}^{n \times n}$을 항상 얻을 수 있으며, 스펙트럼 정리에 의해 가역적 정교직교 기저 P로 다음과 같이 대각화가 가능합니다.

$$A^\top A = PDP^\top \tag{4.71}$$

SVD 식을 주입하여 전개하면 다음과 같습니다.

$$A^\top A = (U\Sigma V^\top)^\top (U\Sigma V^\top) = V\Sigma^\top U^\top U\Sigma V^\top$$

이때 U가 직교 행렬이므로 $U^\top U = \mathbf{I}$가 되어 식은 다음과 같이 정리됩니다.

$$A^\top A = V(\Sigma^\top \Sigma)V^\top \tag{4.73}$$

식 (4.71)과 식 (4.73)을 직접 비교하면 다음 관계가 도출됩니다.

$$V = P, \quad \sigma_i^2 = \lambda_i \tag{4.74-4.75}$$

따라서, **우특이벡터 V의 열벡터들은 $A^\top A$의 정규직교 고유벡터들이며, 특이값 σ_i는 $A^\top A$가 가지는 고유값의 양의 제곱근 $\sqrt{\lambda_i}$**입니다.

2단계: 좌특이벡터 U 구축

동일한 논리로 공역 상에 대칭 행렬 $AA^\top \in \mathbb{R}^{m \times m}$을 구축하여 대각화합니다.

$$AA^\top = (U\Sigma V^\top)(U\Sigma V^\top)^\top = U\Sigma V^\top V\Sigma^\top U^\top = U(\Sigma\Sigma^\top)U^\top \tag{4.76}$$

따라서, **좌특이벡터 U의 열벡터들은 공역 상의 대칭 행렬 $AA^\top$의 정규직교 고유벡터들**로 구성됩니다.

3단계: 두 벡터 군의 연계 및 특이값 방정식

우특이벡터 $\mathbf{v}_i$들은 사상 A를 통과한 이후에도 서로 직교 상태를 유지해야 합니다. 임의의 서로 다른 $i \neq j$에 대하여 다음 내적 값이 성립합니다.

$$(A\mathbf{v}_i)^\top (A\mathbf{v}_j) = \mathbf{v}_i^\top (A^\top A)\mathbf{v}_j = \mathbf{v}_i^\top (\lambda_j \mathbf{v}_j) = \lambda_j \mathbf{v}_i^\top \mathbf{v}_j = 0 \tag{4.77}$$

따라서 이미지 벡터들의 직교성이 보장됩니다. 이 이미지 벡터들을 크기가 1인 정규직교 벡터로 정규화하여 최종 좌특이벡터 $\mathbf{u}_i$를 다음과 같이 얻습니다.

$$\mathbf{u}_i := \frac{A\mathbf{v}_i}{\|A\mathbf{v}_i\|_2} = \frac{1}{\sqrt{\lambda_i}} A\mathbf{v}_i = \frac{1}{\sigma_i} A\mathbf{v}_i \tag{4.78}$$

식 (4.78)의 스칼라 항을 곱해 정리하면 선형대수의 핵심 관계식인 **특이값 방정식 (Singular Value Equation)**이 유도됩니다.

$$A\mathbf{v}_i = \sigma_i \mathbf{u}_i, \quad i = 1, \dots, r \tag{4.79}$$

이 식들을 한데 묶어 행렬 형태로 표기하면 $AV = U\Sigma$가 되며, 양변에 우측으로 $V^\top$를 곱해주면 최종 SVD 식 $A = U\Sigma V^\top$가 도출됩니다.

[예제 4.13] SVD 대수적 계산 예제

다음 2×3 행렬 A의 SVD를 구합니다.

$$A = \begin{bmatrix} 1 & 0 & 1 \\ -2 & 1 & 0 \end{bmatrix} \tag{4.81}$$

1. **$A^\top A$ 대각화를 통한 V 및 특이값 산출**:

$$A^\top A = \begin{bmatrix} 1 & -2 \\ 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 1 \\ -2 & 1 & 0 \end{bmatrix} = \begin{bmatrix} 5 & -2 & 1 \\ -2 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} \tag{4.82}$$

   고유값 방정식 $\det(A^\top A - \lambda \mathbf{I}) = 0$을 풀어 정렬된 세 고유값 $\lambda_1 = 6, \lambda_2 = 1, \lambda_3 = 0$을 구합니다. 따라서 특이값은 $\sigma_1 = \sqrt{6}, \sigma_2 = 1$이며, 랭크는 2입니다. 이에 대응하는 고유벡터들로 구성한 직교행렬 V는 다음과 같습니다.

$$V = \begin{bmatrix} 5/\sqrt{30} & 0 & -1/\sqrt{6} \\ -2/\sqrt{30} & 1/\sqrt{5} & -2/\sqrt{6} \\ 1/\sqrt{30} & 2/\sqrt{5} & 1/\sqrt{6} \end{bmatrix} \tag{4.84}$$

2. **특이값 행렬 Σ 구성**: A와 같은 2×3 크기의 0 패딩 행렬을 작성합니다.

$$\Sigma = \begin{bmatrix} \sqrt{6} & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \tag{4.85}$$

3. **좌특이벡터 U 유도**: 식 (4.78)에 의거하여 계산합니다.

$$\mathbf{u}_1 = \frac{1}{\sqrt{6}} A\mathbf{v}_1 = \frac{1}{\sqrt{6}} \begin{bmatrix} 1 & 0 & 1 \\ -2 & 1 & 0 \end{bmatrix} \begin{bmatrix} 5/\sqrt{30} \\ -2/\sqrt{30} \\ 1/\sqrt{30} \end{bmatrix} = \begin{bmatrix} 1/\sqrt{5} \\ -2/\sqrt{5} \end{bmatrix} \tag{4.86}$$

$$\mathbf{u}_2 = \frac{1}{1} A\mathbf{v}_2 = 1 \begin{bmatrix} 1 & 0 & 1 \\ -2 & 1 & 0 \end{bmatrix} \begin{bmatrix} 0 \\ 1/\sqrt{5} \\ 2/\sqrt{5} \end{bmatrix} = \begin{bmatrix} 2/\sqrt{5} \\ 1/\sqrt{5} \end{bmatrix} \tag{4.87}$$

두 열벡터를 가로로 묶어 최종 직교 행렬 U를 조립합니다.

$$U = \frac{1}{\sqrt{5}} \begin{bmatrix} 1 & 2 \\ -2 & 1 \end{bmatrix} \tag{4.88}$$

> [!WARNING] 손으로 직접 유도하는 위 과정은 컴퓨터 상에서 직접 연산할 시 부동 소수점 수치 오차가 $A^\top A$를 취할 때 증폭되므로 numerical 측면에서 바람직하지 않습니다. 실제 프로그래밍 라이브러리들은 $A^\top A$를 거치지 않고 A 자체에서 다이렉트로 QR 분해 등을 응용한 고성능 알고리즘을 사용합니다.

4.5.3 고유값 분해(Eigendecomposition) vs. 특이값 분해(SVD)

비교 항목	고유값 분해 (Eigendecomposition)	특이값 분해 (SVD)
적용 대상	오직 정사각 행렬 $A \in \mathbb{R}^{n \times n}$만 가능	모든 실수 직사각 행렬 $A \in \mathbb{R}^{m \times n}$ 가능
존재성 보장	대각화 조건(선형 독립 고유벡터 n개) 충족 시에만 존재	**언제나 예외 없이 존재함**
변환 기저 성질	닮음 행렬 P의 열벡터들이 반드시 직교하지는 않음	변환행렬 U, V가 항상 완벽한 직교 행렬(정규직교축)
기저 변환 공간	단일 벡터 공간 내부에서의 동일 좌표 기저 변환 (P와 P^{-1})	서로 다른 두 벡터 공간 간의 상이한 기저 연계 (U와 $V^\top$)
대각행렬의 성질	고유값은 실수뿐만 아니라 복소수, 음수도 가능	특이값은 항상 **실수이며 0 이상(비음)**인 값만 가짐

4.5.4 SVD의 응용: 협업 필터링 (Collaborative Filtering)

SVD는 행렬 내에 잠재된 저차원 구조적 요인을 발굴해낼 수 있습니다.

[예제 4.14] 영화 평점 데이터 분석

3명의 관객(Ali, Beatrix, Chandra)이 4편의 영화(Star Wars, Blade Runner, Amelie, Delicatessen)에 남긴 평점 데이터 행렬 $A \in \mathbb{R}^{4 \times 3}$가 있습니다.

$$A = \begin{bmatrix} 5 & 4 & 1 \\ 5 & 5 & 0 \\ 0 & 0 & 5 \\ 1 & 0 & 4 \end{bmatrix} \begin{matrix} (\text{Star Wars}) \\ (\text{Blade Runner}) \\ (\text{Amelie}) \\ (\text{Delicatessen}) \end{matrix} \tag{4.103-A}$$

SVD를 적용하면 이 평점 행렬은 다음과 같이 분해됩니다 (Figure 4.10 참조).

$$A = U\Sigma V^\top \approx \begin{bmatrix} -0.67 & 0.02 & 0.46 \\ -0.72 & 0.21 & -0.48 \\ -0.09 & -0.77 & -0.53 \\ -0.15 & -0.60 & 0.53 \end{bmatrix} \begin{bmatrix} 9.64 & 0 & 0 \\ 0 & 6.36 & 0 \\ 0 & 0 & 0.71 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} -0.74 & -0.65 & -0.18 \\ 0.09 & 0.18 & -0.98 \\ 0.67 & -0.74 & -0.07 \end{bmatrix}$$

- **좌특이벡터 $\mathbf{u}_i$ (영화 장르 공간)**: $\mathbf{u}_1$을 보면 SF 영화인 Star Wars와 Blade Runner 축의 값이 큰 음수로 높게 나타납니다. 즉, $\mathbf{u}_1$은 'SF 영화 장르'라는 잠재 성향을 대변합니다. 반면 $\mathbf{u}_2$는 프랑스 예술 영화인 Amelie와 Delicatessen 축의 값이 크게 나타나므로 '예술 영화 장르' 성향을 가리킵니다.
- **우특이벡터 $\mathbf{v}_j$ (관객 성향 공간)**: $\mathbf{v}_1$은 SF 장르 평점이 높은 Ali와 Beatrix 성분이 크며, $\mathbf{v}_2$는 예술 영화 평점이 높은 Chandra 성분이 크게 유도됩니다.
- **특이값 Σ (장르별 가중치)**: 첫 번째 특이값 9.64와 두 번째 특이값 6.36에 비해, 세 번째 장르 특이값은 0.71로 극도로 작습니다. 이는 이 관객 데이터 전체를 설명하는 데 오직 2차원의 잠재 공간(SF 장르 및 예술 장르)만으로도 충분히 정보 복원이 가능함을 시사합니다.

4.5.5 SVD의 변형 형식들

SVD는 필요와 행렬 크기에 따라 다음과 같은 축소 행렬 형태로 계산하여 효율성을 도모할 수 있습니다.

- **Full SVD**: 원래 차원을 그대로 지닌 $U_{m\times m}, \Sigma_{m\times n}, V_{n\times n}$의 크기로 행렬 전체를 정직하게 빌드하는 표준 형태입니다.
- **Reduced SVD (Compact SVD)**: 랭크 r 이상으로 넘어가는 0 패딩 행과 열을 생략하여 $U_{m\times r}, \Sigma_{r\times r}, V_{n\times r}$의 크기로 컴팩트하게 축소 분해하는 형태입니다. 대각선 상의 Σ가 온전히 정사각 대각행렬이 되므로 편리합니다.
- **Truncated SVD**: 상위 $k < r$개의 유의미한 특이값만 남기고 강제로 0으로 잘라내어 표현하는 불완전 분해 기법입니다 (행렬 근사에 직접 사용).

4.6 행렬 근사 (Matrix Approximation)

대용량 행렬 데이터를 전부 저장하는 대신, 가장 중요도가 높은 핵심 뼈대 성분만 골라내어 복원하는 기법을 **행렬 저차원 근사 (Low-rank Approximation)**라고 합니다. SVD는 이 분야에서 수학적으로 가장 완벽한 최적의 해를 보장합니다.

4.6.1 외적을 통한 계수 1 행렬의 선형 결합 표현

좌특이벡터 $\mathbf{u}_i \in \mathbb{R}^m$와 우특이벡터 $\mathbf{v}_i \in \mathbb{R}^n$의 외적(Outer product)을 통해 얻어지는 임의의 $m \times n$ 행렬 A_i를 다음과 같이 정의합니다.

$$A_i := \mathbf{u}_i \mathbf{v}_i^\top \tag{4.90}$$

이 A_i는 오직 한 방향의 성분만 가지므로 랭크가 1인 **Rank-1 행렬**이 됩니다. SVD 정리식 $A = U\Sigma V^\top$를 이 외적 행렬들의 선형 결합 형태로 바꾸어 기술하면 다음과 같이 쓸 수 있습니다.

$$A = \sum_{i=1}^{r} \sigma_i \mathbf{u}_i \mathbf{v}_i^\top = \sum_{i=1}^{r} \sigma_i A_i \tag{4.91}$$

즉, 모든 행렬은 서로 수직인 고유한 직교 격자판 역할을 하는 Rank-1 외적 행렬 A_i들을 특이값 σ_i 크기만큼 가중치를 두어 더해 놓은 합산체와 같습니다.

4.6.2 Rank-k 최적 근사 (Rank-k Approximation)

만약 랭크 r까지의 합산 과정을 중간의 지배적인 $k < r$ 지점까지만 진행하고 나머지를 생략하면, 원래 행렬 A와 차원은 같으나 랭크가 k인 근사 행렬 $\widehat{A}^{(k)}$를 얻게 됩니다.

$$\widehat{A}^{(k)} := \sum_{i=1}^{k} \sigma_i \mathbf{u}_i \mathbf{v}_i^{\top} = \sum_{i=1}^{k} \sigma_i A_i \tag{4.92}$$

데이터 압축 비율 예시 (Stonehenge 이미지 압축)

$1,432 \times 1,910$ 해상도의 흑백 이미지 데이터 행렬 A를 그대로 저장하려면 총 $1,432 \times 1,910 = 2,735,120$개의 실수 데이터 공간이 필요합니다. 이를 단 $k = 5$개만의 특이값과 벡터 쌍을 남겨 Rank-5 근사 행렬 $\widehat{A}^{(5)}$로 저축하면, 저장 용량은 다음과 같이 급격하게 절약됩니다.

$$\text{Storage Required} = 5 \times (1,432 + 1,910 + 1) = 16,715$$

이는 원본 데이터 크기의 단 **0.6%** 공간에 불과합니다. 그럼에도 불구하고 Stonehenge의 윤곽과 큰 돌기둥 배치 등 이미지의 주요 시각 정보는 뚜렷하게 관측 및 인식될 수 있습니다 (Figure 4.12 참조).

4.6.3 행렬 노름과 에카르트-영 정리 (Eckart-Young Theorem)

근사 행렬 $\widehat{A}^{(k)}$가 원래 행렬 A와 얼마나 근접하게 최적의 해를 이루는지 이론적으로 보장받기 위해서는 행렬 전체의 크기와 거리를 정량화하는 **행렬 노름(Matrix Norm)**이 필요합니다.

[정의 4.23] 스펙트럼 노름 (Spectral Norm)

임의의 행렬 $A \in \mathbb{R}^{m \times n}$에 대하여, 임의의 비영벡터 $\mathbf{x} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$를 사상시켰을 때 변화하는 벡터 길이의 최대 증폭 비율을 스펙트럼 노름이라 정의하고 $\|A\|_2$로 표기합니다.

$$\|A\|_2 := \max_{\mathbf{x}} \frac{\|A\mathbf{x}\|_2}{\|\mathbf{x}\|_2} \tag{4.93}$$

[정리 4.24] 스펙트럼 노름의 고유 특이값

행렬 A의 스펙트럼 노름은 해당 행렬이 가지는 **가장 큰 특이값 σ_1**과 수학적으로 동일합니다.

$$\|A\|_2 = \sigma_1$$

[정리 4.25] 에카르트-영 정리 (Eckart-Young Theorem)

랭크가 r인 임의의 행렬 $A \in \mathbb{R}^{m \times n}$가 있고, 랭크가 k $(k \leq r)$인 임의의 또 다른 행렬 B를 잡았을 때, **SVD를 상위 k개 성분으로 끊어 생성한 $\widehat{A}^{(k)}$는 다음 최적화 문제의 유일한 해입니다.**

$$\widehat{A}^{(k)} = \arg\min_{\text{rk}(B)=k} \|A - B\|_2 \tag{4.94}$$

이때의 최소 근사 오차 거리는 **잘려 나간 첫 번째 특이값 σ_{k+1}**이 됩니다.

$$\|A - \widehat{A}^{(k)}\|_2 = \sigma_{k+1} \tag{4.95}$$

에카르트-영 정리의 대수학적 증명 아이디어

1. 원래 행렬과 근사 행렬의 차이식은 자르고 남은 $k+1$부터의 잔여 합산에 해당합니다.

$$A - \widehat{A}^{(k)} = \sum_{i=k+1}^{r} \sigma_i \mathbf{u}_i \mathbf{v}_i^{\top} \tag{4.96}$$

   따라서 정리 4.24에 의해 이 차이 행렬의 스펙트럼 노름은 잔여 성분 중 가장 첫 번째 특이값인 σ_{k+1}이 됩니다.
2. 만약 이보다 더 작은 오차 거리를 달성하는 임의의 랭크 k인 행렬 B가 존재한다고 귀류법적 가정을 해 봅시다.

$$\|A - B\|_2 < \|A - \widehat{A}^{(k)}\|_2 = \sigma_{k+1} \tag{4.97}$$

   이 경우, 차원 정리와 커널 공간의 관계에 의해 차원의 총합이 정의역 차원인 n을 초과하게 만드는 비영 공통 벡터가 반드시 두 공간(B의 Null space와 A의 $k+1$ 차원 지배 부분공간)의 교집합 상에 존재하게 됩니다. 이는 결국 수치적인 모순으로 연결되므로, 에카르트-영이 제시한 SVD 근사 방식만이 유일무이한 최적의 근사임을 수학적으로 증명할 수 있습니다.

[예제 4.15] 영화 평점 데이터의 단계별 근사

예제 4.14의 영화 평점 행렬에 대하여 근사를 적용해 봅니다.

1. **Rank-1 근사 ($\widehat{A}^{(1)}$)**: SF 테마 관련 정보만 가지는 첫 번째 항 $A_1 = \mathbf{u}_1 \mathbf{v}_1^{\top}$를 계산하여 가중합을 가합니다.

$$\widehat{A}^{(1)} = \sigma_1 A_1 = \begin{bmatrix} 4.78 & 4.24 & 1.02 \\ 5.23 & 4.75 & -0.03 \\ 0.25 & -0.27 & 4.97 \\ 0.75 & 0.28 & 4.03 \end{bmatrix} \quad (\text{Ali, Beatrix 복원 성공, Chandra 정보 누락}) \tag{4.100}$$

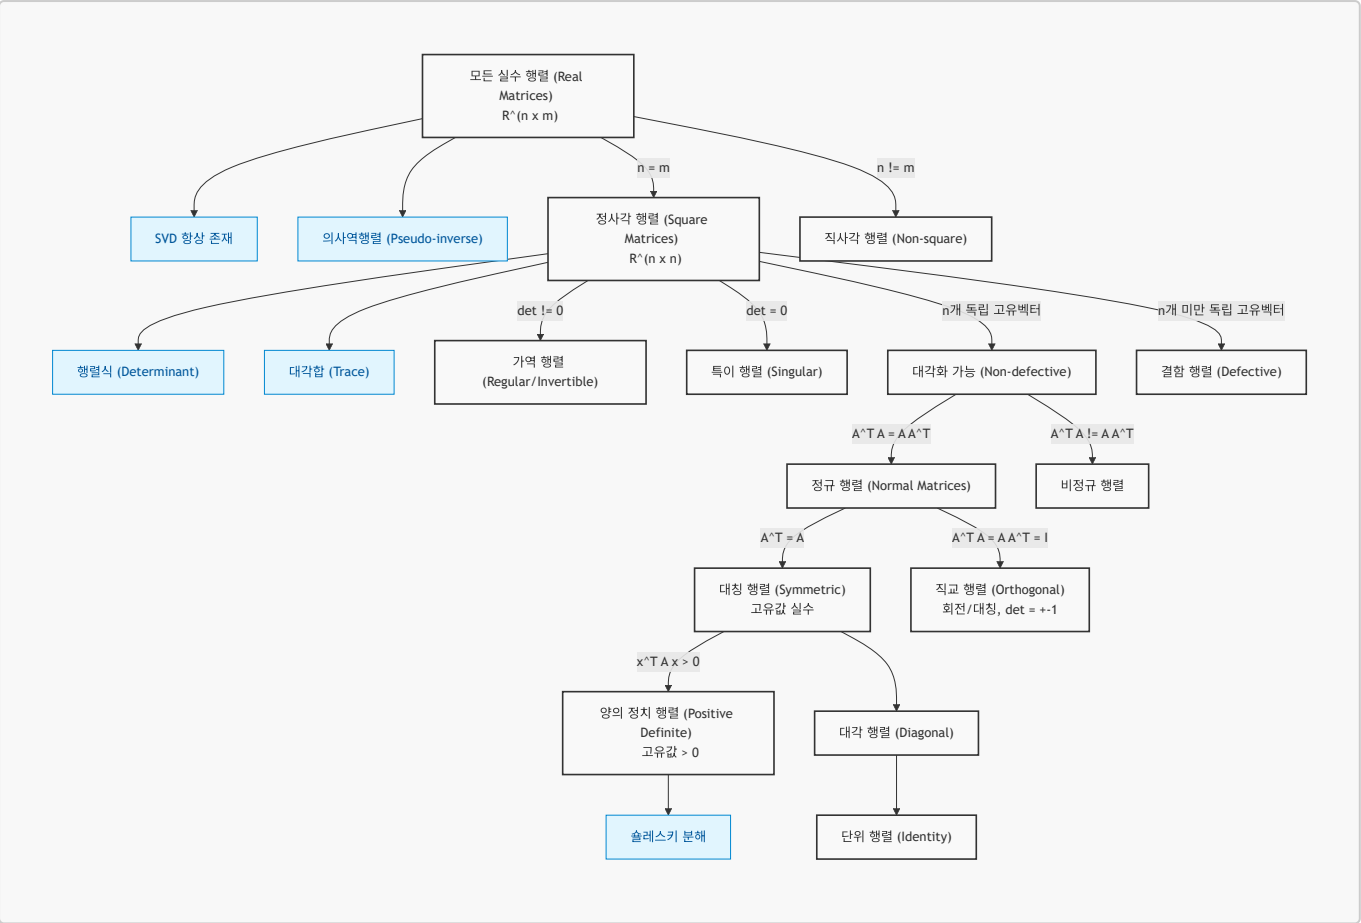
2. **Rank-2 근사 ($\widehat{A}^{(2)}$)**: 예술 영화 성향까지 복구하기 위해 두 번째 장르 항까지 합산합니다.

$$\widehat{A}^{(2)} = \sigma_1 A_1 + \sigma_2 A_2 = \begin{bmatrix} 4.78 & 4.24 & 1.02 \\ 5.23 & 4.75 & -0.03 \\ 0.25 & -0.27 & 4.97 \\ 0.75 & 0.28 & 4.03 \end{bmatrix} \approx \begin{bmatrix} 5 & 4 & 1 \\ 5 & 5 & 0 \\ 0 & 0 & 5 \\ 1 & 0 & 4 \end{bmatrix} = A \tag{4.102}$$

이 결과는 세 번째 성분 $\sigma_3 A_3$의 수치 가중치(0.71)가 지극히 낮기 때문에, 이를 지운 Rank-2 근사만으로도 원래 평점 행렬 A의 기하 구조와 관객 취향을 소수점 수준 이내로 오차 없이 완벽에 가깝게 복구할 수 있음을 검증해 줍니다.

4.7 행렬 계통 분류도 (Matrix Phylogeny)

다양한 형태와 성질을 갖는 행렬들의 포함 관계 및 허용되는 행렬 대수 연산 간의 전체적인 분류 계통도입니다.



- 모든 실수 행렬 $\mathbb{R}^{n\times m}$에 대해 SVD가 항상 존재합니다.
- 가역 행렬(Regular)과 대각화 가능 행렬(Non-defective)은 동의어가 아닙니다. 예를 들어 회전 행렬 R은 행렬식이 1이므로 가역 행렬이지만, 실수 영역에서는 고유값이 존재하지 않아 실수 대각화가 불가능한 대표적인 비정규 행렬입니다.
- 정규 행렬(Normal matrix, $A^\top A = AA^\top$)의 중요한 두 갈래 부분 집합이 실수 고유값만 가지는 **대칭행렬**과 거리를 보존하는 **직교행렬**입니다.
- 대칭행렬 중 양의 고유값만 보유하여 특수한 타원 공간을 묘사하는 집합이 **양의 정치 행렬**이며, 이 집합에 한해 고유한 **숄레스키 분해**가 성립합니다.

4.8 더 읽을거리 (Further Reading)

본 장에서 학습한 수학적 개념들은 단순한 정리를 넘어 컴퓨터가 대형 행렬 연산을 수행하는 하드웨어 가속 블록의 핵심 기초 알고리즘을 이룹니다.

- **행렬 대각합의 활용**: 커널 트릭을 동반하는 머신러닝의 다채로운 **커널 방법론 (Kernel Methods)** 및 가디언트 연산의 역전파 최적화에 깊게 개입합니다.
- **고유값 분해의 활용**: 고차원 공간 데이터의 분산을 최대화하여 압축 투영하는 **주성분 분석 (PCA)**, 데이터를 명확히 분류할 초평면 축을 찾는 **피셔 선형 판별 분석 (LDA)**, 그리고 그래프 이론 기반 분류를 가하는 **스펙트럼 클러스터링 (Spectral Clustering)** 등의 뼈대를 구성합니다.
- **SVD의 확장성**: 2차원 매트릭스를 다차원으로 일반화한 고차원 배열인 텐서(Tensor)에 대해 SVD 성질을 적용하는 **터커 분해(Tucker Decomposition)** 및 **CP 분해(CP Decomposition)**와 같은 현대 다차원 분석론의 직접적인 시발점이 됩니다.

Related Concepts

- MML Study Index
- ML Index

Citations

- Marc Peter Deisenroth, A. Aldo Faisal, Cheng Soon Ong, *Mathematics for Machine Learning* (Chapter 4)