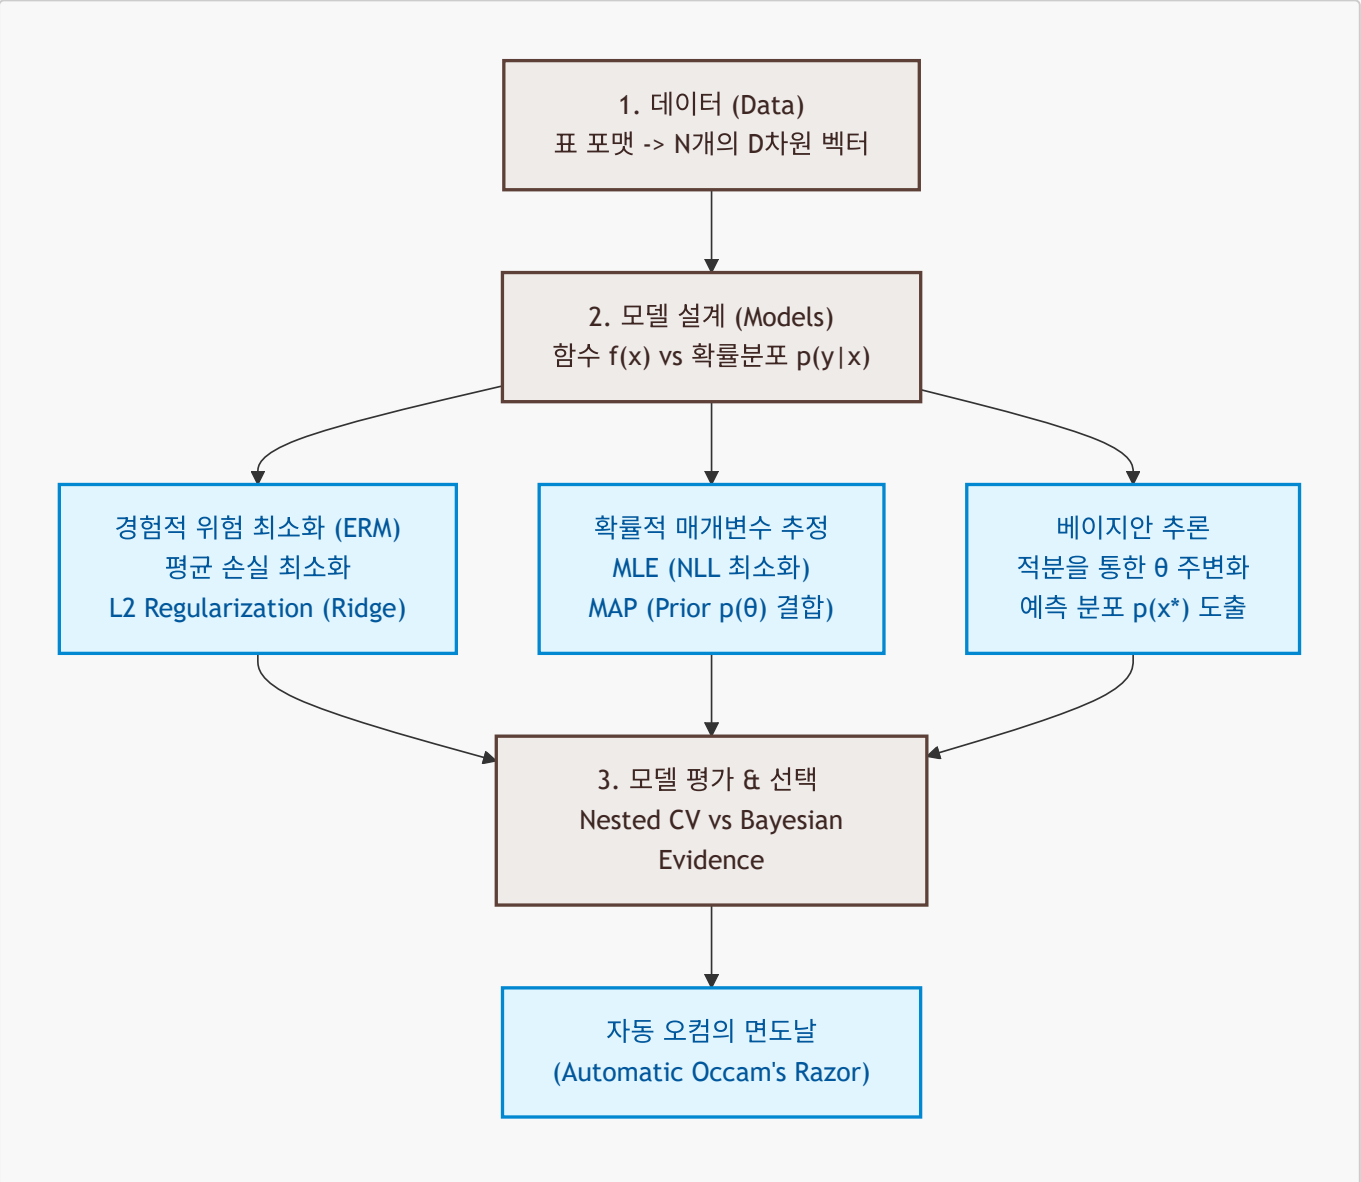
8. 모델과 데이터의 결합 (When Models Meet Data)

본 도서의 1부(Part I)에서는 머신러닝 방법론들의 수학적 뼈대가 되는 **선형대수, 해석기하학, 행렬 분해, 벡터 미분, 확률론, 연속 최적화**의 개념을 학습했습니다. 2부(Part II)부터는 이 수학적 도구들을 유기적으로 결합하여 머신러닝의 4대 기둥인 **회귀 분석(Chapter 9), 차원 축소(Chapter 10), 밀도 추정(Chapter 11), 분류 분석(Chapter 12)** 알고리즘을 설계하고 해결하는 실질적인 과정을 다룹니다.

본 장은 1부의 기초 수학이 어떻게 2부의 구체적인 머신러닝 방법론으로 매끄럽게 연결되는지 다리를 놓아주는 장입니다. 모델의 학습 방식을 크게 **경험적 위험 최소화(ERM)**, **매개변수 추정(MLE/MAP)**, **베이지안 추론(Bayesian Inference)**의 세 가지 패러다임으로 분류하고, 이를 평가하고 선택하는 수학적 원리를 고찰합니다.

[시각 자료] 모델과 데이터의 결합 핵심 개념 흐름도 (Figure 8.15)

데이터를 모델에 피팅하고 성능을 평가하여 모델을 선택하기까지의 전체 프로세스와 핵심 개념들 사이의 대수적 관계를 묘사한 흐름도입니다.



8.1 데이터, 모델, 그리고 학습 (Data, Models, and Learning)

머신러닝의 궁극적인 질문은 **"무엇이 좋은 모델인가?"**입니다. 머신러닝 시스템은 세 가지 핵심 요소로 구성됩니다.

1. **데이터 (Data)**: 현실 세계의 현상을 수치적으로 기록한 것.
2. **모델 (Models)**: 데이터 뒤에 숨겨진 규칙성을 기술하는 수학적 공식 구조.
3. **학습 (Learning)**: 데이터에 부합하도록 모델의 자유 매개변수(Parameters)를 조정하는 수치 최적화 과정.

좋은 모델이란 단순히 기존에 관찰된 데이터를 잘 설명하는 것을 넘어, 아직 관찰되지 않은 **새로운 데이터(Unseen data)에 대해 훌륭한 예측 성능(일반화 성능)**을 보이는 모델을 뜻합니다.

8.1.1 벡터로서의 데이터 (Data as Vectors)

우리는 컴퓨터가 처리할 수 있는 형태의 정형화된 **테이블(Tabular) 형태의 데이터**를 가정합니다.

- 테이블의 **행(Row)**: 개별 데이터 인스턴스(Example, Data point)를 의미하며, N개로 구성됩니다 ($n = 1, \dots, N$).
- 테이블의 **열(Column)**: 각 인스턴스의 특징(Feature, Attribute, Covariate)을 의미하며, D차원으로 구성됩니다 ($d = 1, \dots, D$).

비수치 데이터(예: 성별, 학위, 우편번호)는 적절한 카테고리 매핑이나 지리 좌표(위도/경도) 변환 등을 거쳐 반드시 실수 벡터 공간 $\mathbb{R}^D$ 상의 한 점 $\mathbf{x}_n = [x_n^{(1)}, \dots, x_n^{(D)}]^\top$으로 변환되어야 합니다.

데이터 스케일링 (Data Scaling)

서로 다른 특징 열들이 가지는 수치적 크기 범위가 다르면, 최적화 과정에서 큰 값의 열이 전체를 지배하는 심각한 병태(Poorly conditioned) 문제가 생깁니다. 따라서 추가 정보가 없을 때, 모든 데이터 열의 평균을 0, 분산을 1로 강제 이동 및 조절하는 **표준화(Standardization)** 전처리를 가합니다.

$$\tilde{x}_n^{(d)} = \frac{x_n^{(d)} - \mu_d}{\sigma_d}$$

여기서 μ_d는 d번째 열의 경험적 평균(Empirical mean), σ_d는 경험적 표준편차(Empirical standard deviation)입니다.

- **지도 학습 (Supervised Learning)**: 각 입력 데이터 벡터 $\mathbf{x}_n \in \mathbb{R}^D$마다 목표 타겟값인 라벨 $y_n \in \mathbb{R}$이 함께 짝지어진 쌍 $\{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$을 학습하는 환경입니다. 전체 입력은 행렬 $X \in \mathbb{R}^{N \times D}$로, 라벨은 벡터 $\mathbf{y} \in \mathbb{R}^N$로 쌓아서 표기합니다.

8.1.2 함수의 관점에서의 모델 (Models as Functions)

첫 번째 모델 해석 패러다임은 모델을 단순히 입력 벡터를 받아 출력값을 내놓는 하나의 결정론적 **예측 함수(Predictor)**로 취급하는 것입니다.

$$f : \mathbb{R}^D \to \mathbb{R} \tag{8.1}$$

본 도서에서는 가장 단순하면서도 엄밀한 수학적 토대가 구축된 **선형 함수(Linear functions)**를 기본 모델로 채택합니다.

$$f(\mathbf{x}, \boldsymbol{\theta}) = \boldsymbol{\theta}^\top \mathbf{x} + \theta_0 \tag{8.2}$$

여기서 $\boldsymbol{\theta} \in \mathbb{R}^D$는 가중치 벡터, $\theta_0 \in \mathbb{R}$는 편향(Bias) 매개변수입니다. 대수 연산의 편의를 위해 입력 벡터 맨 앞에 가상의 특징 $x^{(0)} = 1$을 추가하여 $\mathbf{x}_n = [1, x_n^{(1)}, \ldots, x_n^{(D)}]^\top \in \mathbb{R}^{D+1}$로 정의하고, 매개변수 벡터 역시 $\boldsymbol{\theta} = [\theta_0, \theta_1, \ldots, \theta_D]^\top \in \mathbb{R}^{D+1}$로 확장하면 다음과 같이 아핀 함수를 완전한 내적 형태로 압축해 쓸 수 있습니다.

$$f(\mathbf{x}_n, \boldsymbol{\theta}) = \boldsymbol{\theta}^\top \mathbf{x}_n = \theta_0 + \sum_{d=1}^{D} \theta_d x_n^{(d)} \tag{8.4, 8.5}$$

8.1.3 확률 분포의 관점에서의 모델 (Models as Probability Distributions)

두 번째 패러다임은 현실의 데이터가 참 신호(Signal)에 무작위 잡음(Noise)이 뒤섞인 불안정한 상태로 관측된다고 보고, 모델을 **확률 분포(Probability distribution)** 자체로 정의하는 것입니다.

이 방식은 예측값의 단일 지점만을 내놓는 함수 관점과 달리, "해당 예측을 얼마나 확신할 수 있는가"에 대한 **예측 불확실성(Predictive uncertainty)**을 확률 분포의 분산 크기를 통해 정량적으로 제시할 수 있게 해줍니다 (Figure 8.3 참조). 우리는 매개변수의 차원이 유한한 확률 분포족만을 다룸으로써, 무한 차원을 다루는 복잡한 확률 과정(Stochastic process) 이론 없이도 풍부한 확률 모델을 구축합니다.

8.1.4 학습이란 매개변수를 찾는 과정 (Learning is Finding Parameters)

머신러닝의 알고리즘 실행 단계는 대수적으로 다음 세 단계로 엄밀히 구분됩니다.

1. **예측 또는 추론 (Prediction / Inference)**: 훈련이 완전히 끝나 매개변수 $\boldsymbol{\theta}^*$가 고정된 상태에서, 새로운 테스트 데이터 $\mathbf{x}_*$를 입력하여 예측값 $f(\mathbf{x}_*, \boldsymbol{\theta}^*)$을 계산하거나 조건부 확률 분포 $p(y_* \mid \mathbf{x}_*, \boldsymbol{\theta}^*)$를 도출하는 단계입니다.
2. **훈련 또는 매개변수 추정 (Training / Parameter Estimation)**: 준비된 훈련 데이터를 사용하여 모델의 내부 매개변수 $\boldsymbol{\theta}$를 최적화 기법을 동원하여 결정하는 단계입니다.
3. **하이퍼파라미터 튜닝 또는 모델 선택 (Hyperparameter Tuning / Model Selection)**: 모델의 구조나 정칙화 강도 등, 수치적으로 직접 미분하여 최적화하기 곤란한 상위 하이퍼파라미터를 결정하고 복수의 모델 후보군 중 최적을 선택하는 단계입니다.

8.2 경험적 위험 최소화 (Empirical Risk Minimization)

함수 관점의 예측 모델을 학습시킬 때 표준적으로 도입되는 프레임워크가 바로 **경험적 위험 최소화(ERM)**입니다. 여기서는 모델의 불확실성을 표현하는 복잡한 확률 분포 대신, 오직 오차를 정량화하는 실숫값 함수만을 사용하여 최적화를 수행합니다.

8.2.1 가설 함수군 (Hypothesis Class)

학습을 시작하기 전, 우리는 예측기 $f(\mathbf{x}, \boldsymbol{\theta})$가 취할 수 있는 함수의 범위를 미리 한정해야 합니다. 이 허용 가능한 함수들의 총집합을 **가설군(Hypothesis class)** $\mathcal{H}$라고 정의합니다. 예를 들어 선형 회귀의 가설군은 모든 D-차원 아핀 함수들의 집합입니다.

$$\mathcal{H} = \{ f(\cdot, \boldsymbol{\theta}) \mid f(\mathbf{x}, \boldsymbol{\theta}) = \boldsymbol{\theta}^\top \mathbf{x}, \boldsymbol{\theta} \in \mathbb{R}^{D+1} \}$$

학습의 목표는 이 가설군 $\mathcal{H}$ 내부에서 전체 데이터셋에 대해 가장 오차가 적은 최적의 함수(즉, 최적의 매개변수 $\boldsymbol{\theta}^*$)를 건져 올리는 것입니다.

8.2.2 학습을 위한 손실 함수 (Loss Function)

개별 데이터 포인트 $(\mathbf{x}_n, y_n)$에 대하여 모델이 출력한 예측값을 $\hat{y}_n = f(\mathbf{x}_n, \boldsymbol{\theta})$라 정의합니다. 참 라벨 y_n과 예측값 $\hat{y}_n$ 사이의 차이로 인해 유발되는 손실을 측정하는 비음 함수 $\ell(y_n, \hat{y}_n) \geq 0$를 **손실 함수(Loss function)**라고 정의합니다.

데이터의 각 관측값들이 서로 통계적으로 연관되지 않고 동일한 분포에서 독립적으로 추출되었다는 **i.i.d. (Independent and Identically Distributed)** 가정을 채택하면, 전체 N개 데이터셋에 대한 총 오차는 각 샘플 손실들의 단순 평균으로 정의할 수 있습니다. 이를 **경험적 위험(Empirical Risk)** R_{emp}이라고 정의합니다.

$$R_{\text{emp}}(f, X, \mathbf{y}) = \frac{1}{N} \sum_{n=1}^{N} \ell(y_n, f(\mathbf{x}_n, \boldsymbol{\theta})) \tag{8.6}$$

이 경험적 위험 최소화(ERM) 전략은 수학적으로 다음과 같은 최적화 문제로 정식화됩니다.

$$\boldsymbol{\theta}^* = \arg\min_{\boldsymbol{\theta}} R_{\text{emp}}(f, X, \mathbf{y})$$

[예제 8.2] 최소제곱 손실 (Least-Squares Loss)

손실 함수로 오차의 제곱 형태인 $\ell(y_n, \hat{y}_n) = (y_n - \hat{y}_n)^2$을 선택하고, 선형 가설군 $f(\mathbf{x}_n, \boldsymbol{\theta}) = \boldsymbol{\theta}^\top \mathbf{x}_n$을 사용하면 경험적 위험 식은 다음과 같이 유도됩니다.

$$\min_{\boldsymbol{\theta} \in \mathbb{R}^{D+1}} \frac{1}{N} \sum_{n=1}^{N} (y_n - \boldsymbol{\theta}^\top \mathbf{x}_n)^2 \tag{8.8}$$

이를 데이터 행렬 $X \in \mathbb{R}^{N \times (D+1)}$과 라벨 벡터 $\mathbf{y} \in \mathbb{R}^N$을 사용하여 행렬 노름(Norm) 형식으로 간결하게 표현하면 다음과 같으며, 이를 **최소제곱 문제(Least-squares problem)**라고 부릅니다.

$$\min_{\boldsymbol{\theta} \in \mathbb{R}^{D+1}} \frac{1}{N} \|\mathbf{y} - X\boldsymbol{\theta}\|^2 \tag{8.9}$$

경험적 위험(Empirical Risk) vs 참 위험(Expected Risk)

우리가 정작 최소화하고자 하는 궁극적 대상은 가진 훈련 데이터만이 아닌, 세상에 존재할 수 있는 모든 무한한 가상의 데이터 기댓값 하에서의 오차인 **참 위험(Expected Risk / Population Risk)** R_{true}입니다.

$$R_{\text{true}}(f) = \mathbb{E}_{\mathbf{x}, y}\big[\ell(y, f(\mathbf{x}))\big] \tag{8.10}$$

실제로는 무한한 데이터를 얻는 것이 불가능하므로 유한한 데이터로 이루어진 R_{emp}로 대치하여 풀게 되는데, 이 과정에서 태생적으로 **과대적합(Overfitting)**이라는 치명적인 대수적 괴리가 발생하게 됩니다.

8.2.3 과대적합 방지를 위한 정칙화 (Regularization)

만약 가설군 $\mathcal{H}$가 매우 풍부하고 복잡한 함수들(예: 고차 다항식 또는 수억 개의 매개변수를 가진 신경망)을 포함하고 있다면, 최적화 알고리즘은 훈련 데이터 전체를 완벽하게 암기하여 경험적 위험 R_{emp}을 0으로 만들어 버릴 수 있습니다. 이 상태가 되면 모델은 훈련 데이터의 무작위 잡음(Noise)까지 신호로 인식하여 오버피팅을 겪게 되며, 테스트 데이터셋에서의 참 위험 R_{true}은 심각하게 치솟게 됩니다.

이처럼 과도한 유연성을 가진 모델의 자유도를 제한하고 매개변수 탐색 영역을 원점 부근으로 한정시키는 페널티 항을 목적 함수에 더해주는 기법을 **정칙화(Regularization)**라고 합니다.

[예제 8.3] 정칙화된 최소제곱 (Regularized Least Squares / Ridge Regression)

최소제곱 문제식에 매개변수 벡터의 유클리드 L_2 제곱 노름 페널티 항을 더해 정칙화된 최적화 식을 정의합니다.

$$\min_{\boldsymbol{\theta}} \frac{1}{N} \|\mathbf{y} - X\boldsymbol{\theta}\|^2 + \lambda \|\boldsymbol{\theta}\|^2 \tag{8.12}$$

여기서 $\|\boldsymbol{\theta}\|^2 = \boldsymbol{\theta}^\top \boldsymbol{\theta}$를 **정칙화기(Regularizer)**라고 부르며, 수치 최적화 분야에서는 Tikhonov 정칙화, 머신러닝 분야에서는 Ridge 페널티 또는 가중치 감쇠(Weight decay)라고 일컫습니다. 하이퍼파라미터 $\lambda \geq 0$는 **정칙화 매개변수(Regularization parameter)**로, 데이터 오차 최소화와 매개변수 크기 억제 사이의 상충 관계(Trade-off)를 조율합니다. 매개변수 크기가 정칙화에 의해 0 근처로 묶이면 최적화 곡면이 부드러워져 일반화 능력이 향상됩니다.

8.2.4 일반화 평가를 위한 교차 검증 (Cross-Validation)

유한한 크기의 전체 데이터셋 D 하에서 일반화 성능을 정밀하게 평가하기 위해, 데이터를 직접 학습에 사용하는 **훈련 집합(Training set)**과 학습 중 절대 보여주지 않고 최종 일반화 오차만 평가하는 **테스트 집합(Test set)**으로 엄밀하게 분할합니다.

하지만 데이터의 크기가 다소 작을 때 테스트 집합을 크게 떼어 놓으면 모델 훈련을 위한 데이터가 부족해집니다. 반대로 테스트 집합을 너무 작게 설정하면 일반화 오차의 추정치 분산(Variance)이 크게 요동쳐 정확한 검증이 어려워집니다. 이 모순을 극복하기 위해 **K-겹 교차 검증(K-fold Cross-Validation)**을 적용합니다.

1. 전체 데이터를 겹치지 않는 동등한 크기의 K개 조각(Chunks)으로 분할합니다 ($D = C_1 \cup \cdots \cup C_K$).
2. 각 라운드 $k = 1, \ldots, K$마다 k번째 조각 C_k를 검증 집합(Validation set) $V^{(k)}$으로 두고, 나머지 $K-1$개 조각의 합집합을 훈련 집합 $R^{(k)}$로 삼아 모델 $f^{(k)}$를 훈련합니다.
3. 검증 집합 $V^{(k)}$에 대한 평균 오차 $R(f^{(k)}, V^{(k)})$를 구합니다.
4. K개 라운드의 검증 오차를 최종 평균 내어 참 일반화 오차의 기댓값을 근사합니다.

$$\mathbb{E}_{V}\big[R(f, V)\big] \approx \frac{1}{K} \sum_{k=1}^{K} R(f^{(k)}, V^{(k)}) \tag{8.13}$$

교차 검증은 각 폴드 간의 의존성이 전혀 없는 **대단히 병렬화 가능한(Embarrassingly parallel)** 문제이므로, 충분한 하드웨어 자원이 확보된다면 연산 시간을 대폭 줄일 수 있습니다.

8.3 매개변수 추정 (Parameter Estimation)

세 번째 패러다임은 확률론적 표현 방식을 사용하여 데이터 관측 노이즈의 불확실성을 모델링하는 **매개변수 추정(Parameter Estimation)**입니다. 여기서는 손실 함수 대신 **우도(Likelihood)**의 개념을 정의하여 최적화를 수행합니다.

8.3.1 최대 우도 추정 (Maximum Likelihood Estimation, MLE)

데이터 확률 변수 $\mathbf{x}$에 대하여 매개변수 $\boldsymbol{\theta}$를 갖는 확률 밀도 함수군 $p(\mathbf{x} \mid \boldsymbol{\theta})$를 정의합시다. 이미 데이터 $\mathbf{x}$가 관측되어 상수로 고정된 상태에서, 매개변수 $\boldsymbol{\theta}$를 변수로 취급하는 이 함수를 **우도 함수(Likelihood function)**라고 정의합니다.

최적화의 정합성을 위해 우도 함수에 로그를 취하고 부호를 반전시킨 **음의 로그 우도(Negative Log-Likelihood, NLL)** $L(\boldsymbol{\theta})$를 정의하여 최소화 문제를 구성합니다.

$$L(\boldsymbol{\theta}) = -\log p(\mathbf{x} \mid \boldsymbol{\theta}) \tag{8.14}$$

전체 데이터가 i.i.d. 가정 하에 수집되었다면, 조건부 라벨 관측의 결합 우도 $p(\mathbf{y} \mid X, \boldsymbol{\theta})$는 개별 데이터 우도들의 단순 곱으로 인수분해(Factorization)됩니다.

$$p(\mathbf{y} \mid X, \boldsymbol{\theta}) = \prod_{n=1}^{N} p(y_n \mid \mathbf{x}_n, \boldsymbol{\theta}) \tag{8.16}$$

여기에 음의 로그를 취하면 곱셈 연산이 덧셈 연산으로 변환되어 수치적으로 훨씬 안정적이고 미분하기 편리한 NLL 최소화 목적 함수가 완성됩니다.

$$L(\boldsymbol{\theta}) = -\log p(\mathbf{y} \mid X, \boldsymbol{\theta}) = -\sum_{n=1}^{N} \log p(y_n \mid \mathbf{x}_n, \boldsymbol{\theta}) \tag{8.17}$$

[예제 8.5] 가우시안 노이즈 우도로부터의 최소제곱 오차 유도

라벨의 조건부 관측 확률이 참 선형 신호 $\boldsymbol{\theta}^\top \mathbf{x}_n$에 가우시안 백색 잡음 $\epsilon_n \sim \mathcal{N}(0, \sigma^2)$이 더해진 형태라고 정식화해 봅시다.

$$y_n = \boldsymbol{\theta}^\top \mathbf{x}_n + \epsilon_n \implies p(y_n \mid \mathbf{x}_n, \boldsymbol{\theta}) = \mathcal{N}(y_n \mid \boldsymbol{\theta}^\top \mathbf{x}_n, \sigma^2) \tag{8.15}$$

이 가우시안 우도 가정을 NLL 공식에 대입하여 대수적으로 끝까지 전개해 봅시다.

\begin{aligned} L(\boldsymbol{\theta}) &= -\sum_{n=1}^N \log \left[\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_n - \boldsymbol{\theta}^\top \mathbf{x}_n)^2}{2\sigma^2} \right) \right] \tag{8.18b} \\ &= -\sum_{n=1}^N \left[-\frac{(y_n - \boldsymbol{\theta}^\top \mathbf{x}_n)^2}{2\sigma^2} - \log \sqrt{2\pi\sigma^2} \right] \tag{8.18c} \\ &= \frac{1}{2\sigma^2} \sum_{n=1}^N (y_n - \boldsymbol{\theta}^\top \mathbf{x}_n)^2 + \frac{N}{2} \log (2\pi\sigma^2) \tag{8.18d} \end{aligned}

노이즈의 분산 σ^2이 상수로서 주어져 있다면, 두 번째 로그 항은 매개변수 $\boldsymbol{\theta}$와 완전히 독립된 상수이므로 최적화 경로에서 무시됩니다. 또한 첫 번째 항의 가중 계수 $\frac{1}{2\sigma^2}$ 역시 양의 상수이므로 최적점의 위치에 영향을 주지 않습니다. 결과적으로 가우시안 노이즈 우도 하에서의 최대 우도 추정(MLE)은 **경험적 위험 최소화(ERM) 하에서의 최소제곱(Least-Squares) 문제식 (8.8)을 푸는 것과 완전히 일치함**이 수학적으로 증명됩니다.

8.3.2 최대 사후 확률 추정 (Maximum A Posteriori Estimation, MAP)

만약 우리가 학습을 시작하기 전, 매개변수 $\boldsymbol{\theta}$가 특정 범위 내에 존재할 확률이 높다는 식의 **사전 지식(Prior knowledge)**을 확률 분포 $p(\boldsymbol{\theta})$의 형태로 가지고 있다면, 이를 우도 함수에 결합할 수 있습니다.

데이터 관측값 X를 목격한 후 업데이트된 매개변수의 사후 확률 분포 $p(\boldsymbol{\theta} \mid X)$는 **베이즈 정리(Bayes' Theorem)**에 의해 다음과 같이 도출됩니다.

$$p(\boldsymbol{\theta} \mid X) = \frac{p(X \mid \boldsymbol{\theta}) p(\boldsymbol{\theta})}{p(X)} \tag{8.19}$$

매개변수의 최적값을 찾는 최적화 관점에서는 매개변수 $\boldsymbol{\theta}$와 완전히 독립적인 분모의 주변 우도(Marginal likelihood) $p(X)$를 상수 취급하여 생략할 수 있습니다.

$$p(\boldsymbol{\theta} \mid X) \propto p(X \mid \boldsymbol{\theta}) p(\boldsymbol{\theta}) \tag{8.20}$$

여기에 음의 로그를 취하여 음의 로그 사후 확률을 최소화하는 문제를 정의하며, 이를 **최대 사후 확률 추정(MAP Estimation)**이라고 합니다.

$$-\log p(\boldsymbol{\theta} \mid X) = -\log p(X \mid \boldsymbol{\theta}) - \log p(\boldsymbol{\theta}) + \text{const}$$

이 식에서 알 수 있듯, 우도 항 $-\log p(X \mid \boldsymbol{\theta})$ 뒤에 더해진 사전 분포 항 $-\log p(\boldsymbol{\theta})$은 비확률론적 ERM 프레임워크에서의 **정칙화 페널티 항(Regularization term)**과 완벽히 상응하는 대수적 구조를 이룹니다. 예를 들어, 매개변수에 평균이 0인 독립 가우시안 사전 분포 $p(\boldsymbol{\theta}) = \mathcal{N}(\mathbf{0}, \sigma_0^2 I)$를 부과하고 음의 로그를 취하면 매개변수의 제곱합인 $\|\boldsymbol{\theta}\|^2$ 페널티가 자연스럽게 튀어나옵니다. 즉, **가우시안 Prior를 적용한 MAP 추정은 L_2 정칙화(Ridge Regression)와 수학적으로 정확히 동치**입니다.

8.3.3 모델 피팅 상태의 분류 (Model Fitting)

훈련 데이터에 모델을 최적화(피팅)하고 난 후, 우리는 매개변수의 수용 공간 크기와 데이터 적합 상태에 따라 다음과 같은 세 가지 시나리오를 마주하게 됩니다 (Figure 8.8 참조).

1. **과대적합 (Overfitting)**: 모델 클래스가 타겟 현상에 비해 지나치게 많은 매개변수를 담고 있어(즉, 너무 유연하여), 데이터 본연의 경향성뿐 아니라 관측에 내재된 무작위 잡음까지 완벽하게 적합해 버린 상태입니다. 훈련 오차는 0에 수렴하지만 일반화 에러는 극도로 나빠집니다.
2. **과소적합 (Underfitting)**: 모델 클래스가 타겟 현상을 설명하기에 너무 단순한 가설군으로 제약되어 있어(예: 구불구불한 데이터를 직선 모델로 피팅), 데이터의 주요 경향성조차 반영하지 못하는 상태입니다. 훈련 오차와 테스트 오차 모두 높게 나타납니다.
3. **적절한 적합 (Fitting Well)**: 모델 클래스의 복잡도가 실제 현상의 복잡도와 절묘하게 정합하여, 잡음을 효과적으로 걸러내면서도 본질적인 경향성을 성공적으로 포착해 낸 이상적인 일반화 상태입니다.

8.4 확률적 모델링과 추론 (Probabilistic Modeling and Inference)

최대 우도 추정(MLE)과 최대 사후 확률 추정(MAP)은 결국 단 하나의 '가장 유력한' 매개변수 점 추정치 $\boldsymbol{\theta}^*$만을 계산하여 예측 함수 $f(\mathbf{x}, \boldsymbol{\theta}^*)$를 조립하는 방식입니다. 반면 **베이즈 추론(Bayesian Inference)**은 매개변수 $\boldsymbol{\theta}$를 단일한 상수가 아닌, 학습 과정 전체에 걸쳐 불확실성을 수반하는 **확률 변수(Random variable)** 그 자체로 취급합니다.

8.4.1 확률 모델의 정식화

확률 모델을 정의한다는 것은 관측된 데이터 변수 $\mathbf{x}$와 보이지 않는 숨겨진 매개변수 변수 $\boldsymbol{\theta}$의 **결합 확률 분포(Joint probability distribution)** $p(\mathbf{x}, \boldsymbol{\theta})$를 선언하는 것과 정확히 같습니다. 곱의 법칙(Product rule)에 의해 결합 분포를 사전 분포와 우도의 곱으로 표현할 수 있습니다.

$$p(\mathbf{x}, \boldsymbol{\theta}) = p(\mathbf{x} \mid \boldsymbol{\theta}) p(\boldsymbol{\theta})$$

이 결합 분포 하나만 명확히 정의해 두면, 적분(Marginalization)과 나눗셈 연산만으로 주변 우도 $p(\mathbf{x})$, 사후 분포 $p(\boldsymbol{\theta} \mid \mathbf{x})$를 수학적 일관성을 유지하며 전부 유도해낼 수 있습니다.

8.4.2 베이즈 추론 (Bayesian Inference)

베이즈 추론의 목표는 단일점 $\boldsymbol{\theta}^*$를 골라내는 최적화 문제를 푸는 것이 아니라, 관측 데이터 X를 반영하여 매개변수의 불확실성 전체를 나타내는 **사후 확률 분포(Posterior distribution)** $p(\boldsymbol{\theta} \mid X)$의 분포 형태 전체를 계산해내는 것입니다.

$$p(\boldsymbol{\theta} \mid X) = \frac{p(X \mid \boldsymbol{\theta}) p(\boldsymbol{\theta})}{p(X)} \tag{8.22}$$

여기서 분모의 **marginal likelihood(주변 우도 / Model evidence)** $p(X)$는 다음과 같이 매개변수 공간 전체에 대해 우도와 사후 확률의 곱을 적분하여 매개변수를 완전히 없앤(Marginalized) 데이터 자체의 생성이 나타날 확률입니다.

$$p(X) = \int_{\boldsymbol{\theta}} p(X \mid \boldsymbol{\theta}) p(\boldsymbol{\theta}) d\boldsymbol{\theta} \tag{8.22}$$

예측 분포 (Predictive Distribution)의 대수적 도출

새로운 입력 데이터 $\mathbf{x}_*$가 주어졌을 때, 베이즈 추론 하에서의 예측 분포 $p(y_* \mid \mathbf{x}_*, X)$는 단일 매개변수를 사용하는 대신, 사후 분포 $p(\boldsymbol{\theta} \mid X)$가 가리키는 모든 가능한 매개변수 후보군들의 예측 능력을 각각의 확률 크기로 가중 평균(Marginalization 적분)하여 결정합니다.

$$p(y_* \mid \mathbf{x}_*, X) = \int_{\boldsymbol{\theta}} p(y_* \mid \mathbf{x}_*, \boldsymbol{\theta}) p(\boldsymbol{\theta} \mid X) d\boldsymbol{\theta} \tag{8.23}$$

이 적분을 수행함으로써 매개변수의 추정 불확실성이 예측값으로 정밀하게 전파(Propagation of uncertainty)됩니다.

> [!CAUTION] **베이지안 추론의 계산적 장벽: 적분(Integration) 문제** 점 추정(MLE/MAP)의 핵심 연산은 경사하강법으로 극대값을 찾는 **최적화(Optimization)** 연산인 반면, 베이즈 추론의 핵심 연산은 주변 우도와 예측 분포를 구하기 위해 고차원 매개변수 공간 전체를 뭉개어 합치는 **적분(Integration)** 연산입니다. 만약 우도와 사전 분포가 켤레(Conjugate) 관계가 아니라면 이 적분식은 수학적으로 닫힌 형식(Closed-form)의 해석적 해를 구할 수 없는 난제가 됩니다. 이 경우 마르코프 체인 몬테카를로(MCMC)와 같은 확률적 샘플링 근사 기법이나, 라플라스 근사, 변분 추론(Variational Inference, VI), 기대값 전파(EP) 같은 결정론적 최적화 우회 근사 기법을 사용해야만 합니다.

8.4.3 잠재 변수 모델 (Latent-Variable Models)

실제 데이터 생성 메커니즘을 보다 명밀하게 설명하기 위해, 모델 매개변수 $\boldsymbol{\theta}$ 외에 각 데이터 샘플 마다 개별적으로 대응되는 관측되지 않은 또 다른 숨겨진 확률 변수인 **잠재 변수(Latent variable) $\mathbf{z}$**를 명시적으로 도입하여 모델을 설계하기도 합니다.

잠재 변수 모델의 결합 확률 분포는 다음과 같이 정의됩니다.

$$p(\mathbf{x}, \mathbf{z} \mid \boldsymbol{\theta}) = p(\mathbf{x} \mid \mathbf{z}, \boldsymbol{\theta}) p(\mathbf{z})$$

이 모델에서 관측 데이터의 주변 우도(Likelihood)는 숨겨진 잠재 변수 $\mathbf{z}$ 공간 전체에 대해 적분(주변화)을 취해 소거해 줌으로써 도출됩니다.

$$p(\mathbf{x} \mid \boldsymbol{\theta}) = \int_{\mathbf{z}} p(\mathbf{x} \mid \mathbf{z}, \boldsymbol{\theta}) p(\mathbf{z}) d\mathbf{z} \tag{8.25}$$

잠재 변수 $\mathbf{z}$가 소거된 우도 함수 식 (8.25)가 도출되면, 이를 사용하여 앞서 다룬 MLE 및 MAP 최적화를 동일하게 적용할 수 있습니다. 또한 매개변수 $\boldsymbol{\theta}$를 고정한 상태에서 특정 데이터 관측값 $\mathbf{x}$가 주어졌을 때 잠재 변수의 상태를 추론하는 **잠재 변수 사후 분포**는 다음과 같이 계산됩니다.

$$p(\mathbf{z} \mid \mathbf{x}, \boldsymbol{\theta}) = \frac{p(\mathbf{x} \mid \mathbf{z}, \boldsymbol{\theta}) p(\mathbf{z})}{p(\mathbf{x} \mid \boldsymbol{\theta})} \tag{8.28}$$

이러한 잠재 변수 모델의 최적 매개변수를 구하는 대표적인 수치 알고리즘이 바로 **기대값 극대화(Expectation-Maximization, EM) 알고리즘**이며, 차원 축소의 PCA(Chapter 10) 및 밀도 추정의 가우시안 혼합 모델(Chapter 11)에서 그 구체적인 대수 전개와 작동 원리를 학습하게 됩니다.

8.5 방향성 그래픽 모델 (Directed Graphical Models)

확률 모델을 설계할 때 확률 변수들의 개수가 많아지면 결합 확률 분포 식의 결합 관계가 극도로 복잡해집니다. 이 변수들 간의 조건부 의존성(Conditional dependency)과 독립성 관계를 시각적으로 한눈에 파악하고 컴팩트하게 표기하기 위해 **방향성 그래픽 모델(Directed Graphical Model / Bayesian Network)**을 사용합니다.

8.5.1 그래프의 문법과 판독 법칙 (Graph Semantics)

그래픽 모델을 구성하는 대수적 규칙은 다음과 같습니다.

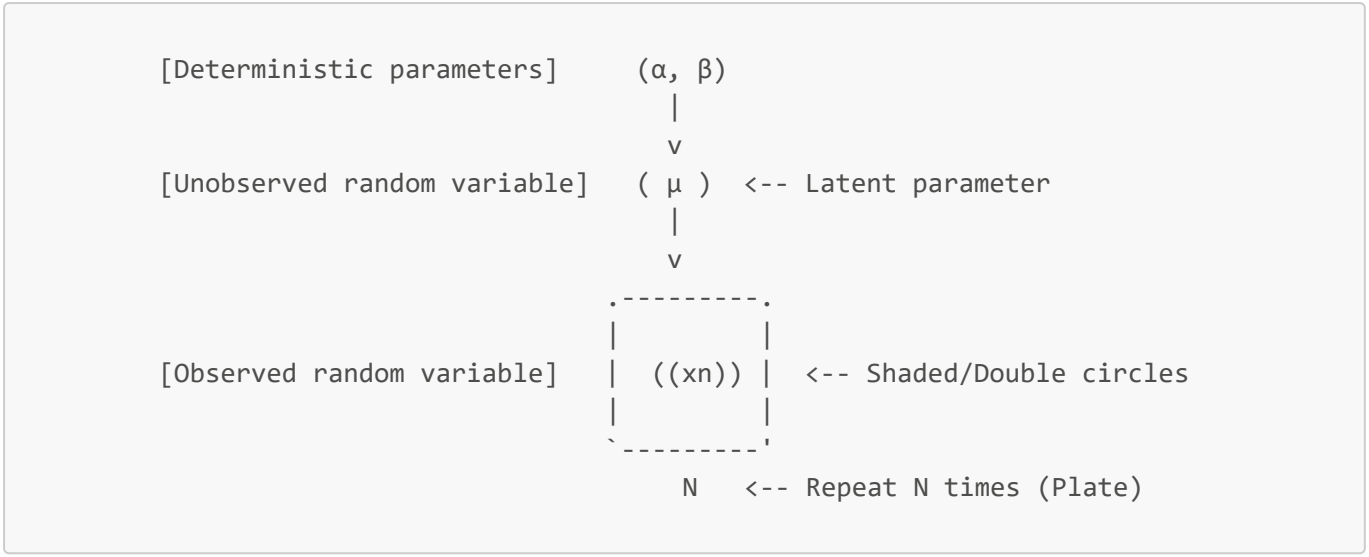
1. **노드(Node)**: 각각의 무작위 확률 변수를 나타냅니다.
   - **하얀색 빈 노드**: 관측되지 않은 숨겨진 변수 또는 매개변수 ($\boldsymbol{\theta}, \mathbf{z}$ 등)
   - **음영 처리된 노드**: 실제로 값을 목격하여 상수로 고정된 관측 변수 ($\mathbf{x}$ 등)
2. **방향 화살표(Directed Edge)**: 조건부 의존성(Conditional probability)을 나타냅니다. 예를 들어 노드 a에서 노드 b로 향하는 화살표($a \rightarrow b$)는 조건부 확률 $p(b \mid a)$ 항이 결합 분포에 곱해짐을 뜻합니다. 이때 a를 b의 **부모 노드(Parent node)**라고 부릅니다.

그래프 상에 나타난 모든 부모-자식 화살표 구조를 활용하면, 복잡한 다차원 결합 확률 분포를 개별 자식 노드가 자신의 부모 노드들(Pa_k)에만 종속되는 조건부 확률들의 단순 곱으로 완벽히 분해(Factorization)하여 정의할 수 있습니다.

$$p(\mathbf{x}_1, \ldots, \mathbf{x}_K) = \prod_{k=1}^{K} p(\mathbf{x}_k \mid \mathrm{Pa}_k) \tag{8.31}$$

[시각 자료] 그래픽 모델의 기본 노드 표현 및 플레이트 표기법 (Figure 8.10)

동일한 독립 실험을 N번 반복할 때 개별 노드를 일렬로 중복해서 그리는 비효율을 방지하기 위해, 반복 영역을 묶어 우하단에 반복 횟수 N을 기입하는 **플레이트 표기법(Plate notation)**을 사용합니다. 아래는 하이퍼파라미터 α, β의 지배를 받는 파라미터 μ에 기해 N개의 관측 $\mathbf{x}_n$이 독립 생성되는 베이지안 그래픽 모델의 도식입니다.



8.5.2 조건부 독립성과 d-분리 (d-Separation)

그래픽 모델의 가장 강력한 용도는 확률 분포의 대수적 식을 직접 계산해보지 않고도, 오직 화살표의 연결 기하학적 구조만 보고 임의의 두 확률 변수 집합 A와 B가 특정 변수 집합 C가 주어졌을 때 서로 **조건부 독립(Conditionally Independent)** 관계 $A \perp\!\!\!\perp B \mid C$인지 즉시 판독해낼 수 있다는 점입니다. 이 판독 규칙을 **d-분리(d-separation)**라고 부릅니다.

d-분리 차단 판정 알고리즘

A에서 출발하여 화살표의 원래 방향을 완전히 무시한 채 선을 타고 B에 도달하는 모든 가능한 가상의 경로(Trail)를 추적합니다. 특정 경로 상에 존재하는 임의의 노드 v에 대해 다음 두 조건 중 **단 하나라도 충족되면 해당 경로는 차단(Blocked)**되었다고 판정합니다.

1. **꼬리-머리($\rightarrow v \rightarrow$) 또는 꼬리-꼬리($\leftarrow v \rightarrow$) 구조**에서, 중간 노드 v가 우리가 알고 조건부로 준 관측 집합 C에 포함되는 경우 ($v \in C$).
2. **머리-머리($\rightarrow v \leftarrow$) 충돌(Collider) 구조**에서, 충돌 노드 v와 그 노드의 어떠한 후손(Descendants) 노드들도 전부 관측 집합 C에 포함되지 않는 경우 ($v \notin C$ 이고 후손 $\notin C$).

만약 A와 B를 잇는 모든 가능한 경로가 최소 하나 이상의 노드에 의해 완벽하게 차단되어 통행이 불가능하다면, A와 B는 C에 의해 **d-separated** 되었다고 하며, 실제 확률 분포 상에서 조건부 독립성 $A \perp\!\!\!\perp B \mid C$가 보장됩니다.

8.6 모델 선택 (Model Selection)

우리는 하이퍼파라미터(예: 다항식 차수, 신경망 층수, 정칙화 계수 λ)를 조절하여 모델의 복잡도와 가설 공간 $\mathcal{H}$의 크기를 변경합니다. 최적의 일반화 능력을 갖추기 위해 상이한 복잡도를 지닌 모델 후보군 중 최선의 하나를 골라내는 이론을 **모델 선택(Model Selection)**이라고 합니다.

8.6.1 Nested 교차 검증 (Nested Cross-Validation)

모델의 가중치 매개변수 $\boldsymbol{\theta}$를 훈련하면서 동시에 최적의 하이퍼파라미터 λ를 탐색할 때, 일반적인 1차원 교차 검증을 사용하면 하이퍼파라미터 정보가 검증 집합으로 누수(Leakage)되어 최종 일반화 성능 평가가 편향됩니다. 이를 완벽하게 차단하기 위해 이중 루프로 교차 검증을 수행하는 **Nested 교차 검증**을 구현합니다 (Figure 8.13 참조).

1. **외곽 루프 (Outer Loop)**: 전체 데이터를 훈련 데이터와 테스트 데이터로 분할합니다. 최종 모델의 순수한 일반화 성능을 평가하는 용도입니다.
2. **내부 루프 (Inner Loop)**: 외곽 루프의 훈련 데이터를 다시 내부 훈련 데이터와 내부 검증 데이터로 한 번 더 분할하여 교차 검증을 가합니다. 다양한 하이퍼파라미터 후보군 중 내부 검증 오차 평균 (8.39)을 가장 최소화하는 '최적의 하이퍼파라미터'를 건져내는 용도입니다.
3. 내부 루프에서 결정된 최적의 하이퍼파라미터를 사용하여 외곽 루프의 전체 훈련 데이터로 모델을 재훈련한 뒤, 외곽의 테스트 데이터로 최종 성능을 측정합니다.

8.6.2 베이즈 모델 선택과 오컴의 면도날 (Bayesian Model Selection & Occam's Razor)

비베이지안 패러다임에서는 모델 선택을 위해 CV를 돌려 모델을 수십 수백 번 재훈련해야 하는 극심한 계산적 비용을 지불해야 합니다. 반면 베이지안 프레임워크에서는 모델 M_k 자체의 불확실성을 상위 계층의 확률 변수로 두어 계층적 베이지안 모델을 구축함으로써 단 한 번에 모델 선택을 수행합니다.

데이터 D가 관측되었을 때 특정 모델 구조 M_k가 진실일 사후 확률 $p(M_k \mid D)$는 다음과 같습니다.

$$p(M_k \mid D) \propto p(M_k)p(D \mid M_k) \tag{8.43}$$

여기서 곱해지는 **모델 에비던스(Model Evidence / Marginal Likelihood)** $p(D \mid M_k)$는 다음과 같이 모델 M_k가 가진 매개변수 $\boldsymbol{\theta}_k$ 전체를 적분하여 날려버린 값입니다.

$$p(D \mid M_k) = \int_{\boldsymbol{\theta}_k} p(D \mid \boldsymbol{\theta}_k)p(\boldsymbol{\theta}_k \mid M_k)d\boldsymbol{\theta}_k \tag{8.44}$$

자동 오컴의 면도날 (Automatic Occam's Razor)

수학적으로 확률 분포는 모든 가능한 데이터 공간 D에 대해 적분하면 반드시 1이 되어야 합니다 ($\int p(D \mid M)dD = 1$).

- **단순한 모델** M_1: 극히 제한된 종류의 단순한 데이터셋만을 생성할 수 있으므로, 그 좁은 데이터 영역에 확률 밀도를 높게 밀집시켜 분포시킵니다.
- **지나치게 복잡한 모델** M_2: 수많은 자유 매개변수 덕분에 세상의 거의 모든 기기괴괴한 데이터셋을 다 흉내 내어 설명할 수 있습니다. 하지만 확률 보존 법칙($\text{Sum} = 1$)으로 인해 확률 밀도가 모든 데이터 영역으로 아주 얇고 넓게 흩어지게 됩니다.

만약 우리가 실제로 목격한 데이터 D가 단순한 형태 영역에 위치한다면, 복잡한 모델 M_2의 에비던스 값 $p(D \mid M_2)$은 얇게 퍼진 확률 밀도 때문에 극히 작게 떨어집니다. 반면 단순한 모델 M_1의 에비던스 $p(D \mid M_1)$은 좁은 곳에 뭉쳐진 밀도 덕분에 훨씬 크게 나타납니다. 따라서 베이즈 모델 사후 확률을 극대화하면, 인위적인 페널티 항을 수동으로 조절하지 않아도 **현상을 설명할 수 있는 가장 단순한 모델을 자동으로 선택하게 되는 오컴의 면도날 법칙**이 수학적으로 자동 내재화되어 작동합니다 (Figure 8.14 참조).

8.6.3 모델 비교를 위한 베이즈 인자 (Bayes Factors)

두 구체적인 경쟁 모델 M_1, M_2에 대한 사후 확률의 비율인 **사후 오즈(Posterior odds)**를 계산하여 모델 비교를 수행합니다.

$$\frac{p(M_1 \mid D)}{p(M_2 \mid D)} = \left(\frac{p(M_1)}{p(M_2)}\right)\left(\frac{p(D \mid M_1)}{p(D \mid M_2)}\right) \tag{8.46}$$

- **우변 첫 번째 항**: 학습 전 두 모델에 대해 가졌던 선호도 비율인 **사전 오즈(Prior odds)**입니다. 보통 균등분포($1/2$)를 가하여 1로 소거합니다.
- **우변 두 번째 항**: 두 모델의 marginal likelihood 비율인 **베이즈 인자(Bayes factor)** B_{12}입니다.

$$B_{12} = \frac{p(D \mid M_1)}{p(D \mid M_2)} \tag{8.47}$$

베이즈 인자 $B_{12} > 1$이면 데이터가 모델 M_1을 지지하는 것이고, $B_{12} < 1$이면 M_2를 지지하는 것으로 명확하게 판정합니다.

[정리] 정보 기준 (Information Criteria)을 통한 간이 모델 선택

모델 에비던스의 어려운 고차원 적분을 대수적으로 근사하거나, MLE의 과대적합 편향을 보정하기 위해 점 추정 정보에 페널티를 더한 간이 지표들을 활용합니다.

1. **아카이케 정보 기준 (AIC: Akaike Information Criterion)**:

$$\mathrm{AIC} = \log p(D \mid \boldsymbol{\theta}_{\mathrm{ML}}) - M \tag{8.48}$$

   여기서 M은 모델의 자유 매개변수 개수입니다. 더 복잡한 모델이 유발하는 최대 우도의 낙관적 편향을 매개변수 수 만큼 선형 페널티로 직접 깎아내어 보정합니다.
2. **베이지안 정보 기준 (BIC: Bayesian Information Criterion)**:

$$\mathrm{BIC} = \log p(D \mid \boldsymbol{\theta}_{\mathrm{ML}}) - \frac{1}{2} M \log N \tag{8.49}$$

   여기서 N은 데이터 샘플 개수입니다. 이는 하부의 사전 분포가 완만한 상태에서의 모델 에비던스 $\log p(D)$를 라플라스 근사법(Laplace approximation)을 사용하여 2차 테일러 전개하여 유도해낸 대수적 근사치입니다. 데이터 개수 N이 커질수록 복잡한 모델에 AIC보다 훨씬 가혹한 벌점을 부과합니다.

Citations

- Marc Peter Deisenroth, A. Aldo Faisal, and Cheng Soon Ong, *Mathematics for Machine Learning*, Cambridge University Press, 2020. (Chapter 8: When Models Meet Data)
- Christopher M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006.
- David J.C. MacKay, *Information Theory, Inference and Learning Algorithms*, Cambridge University Press, 2003.
- Judea Pearl, *Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference*, Morgan Kaufmann, 1988.