11. 혼합 가우시안 모델을 통한 밀도 추정 (Density Estimation with GMM)

기계학습의 3대 지지대 중 회귀 분석(Regression, 9장)과 차원 축소(Dimensionality Reduction, 10장)를 앞서 살펴보았습니다. 본 장에서는 세 번째 기둥에 해당하는 **밀도 추정(Density Estimation)**을 학습합니다.

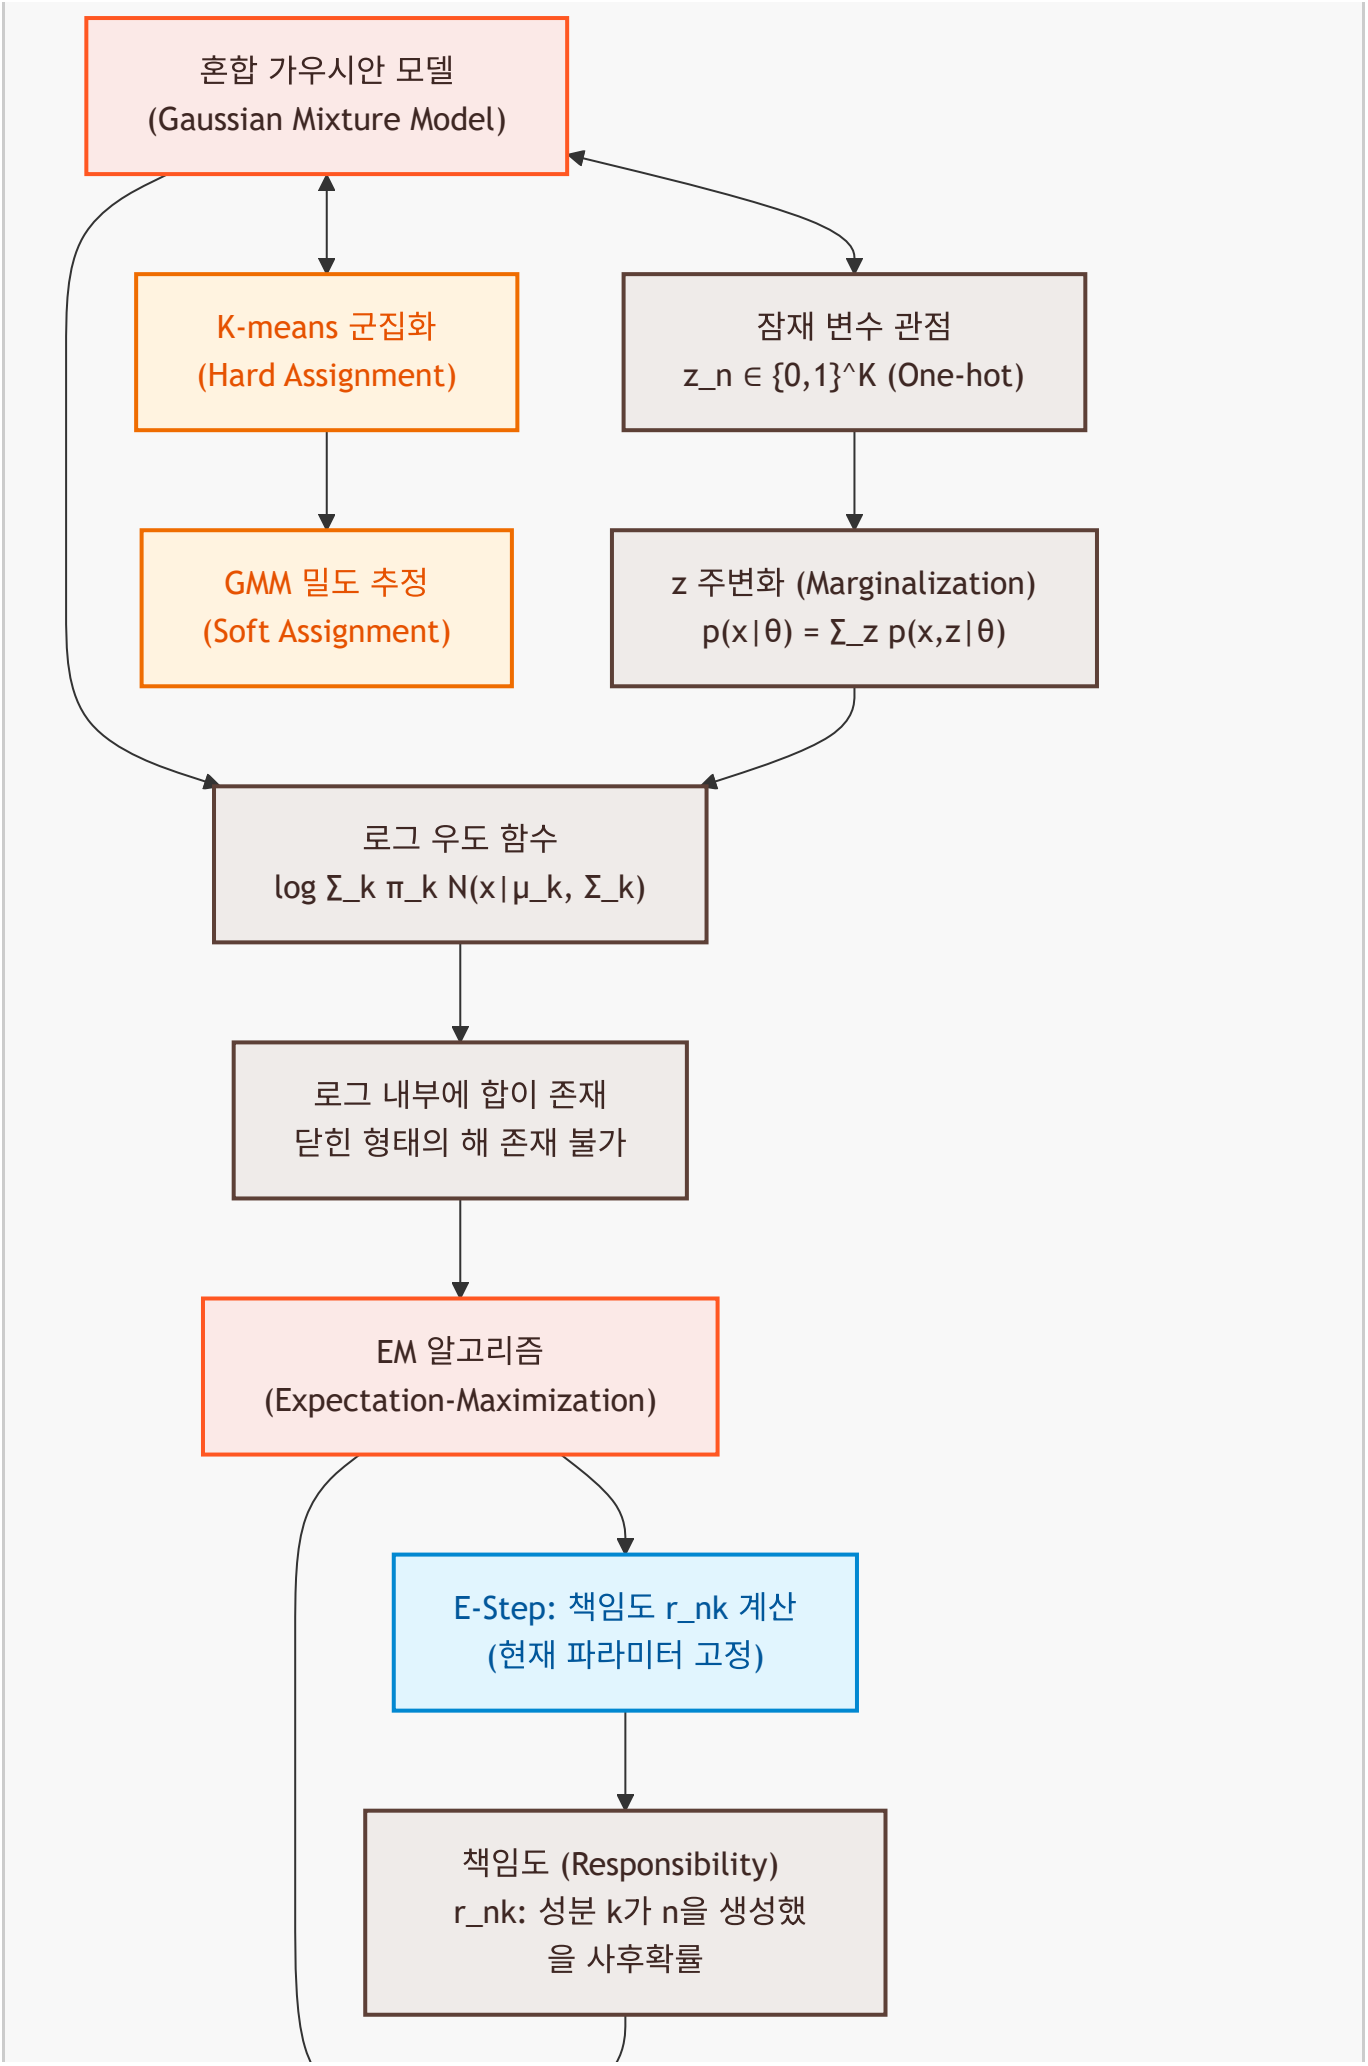
밀도 추정이란 주어진 데이터셋 $X = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$이 추출되었을 것으로 추정되는 미지의 참 확률 밀도 함수(Probability Density Function) $p(\mathbf{x})$를 수학적 모델을 통해 근사하는 과정입니다. 데이터를 컴팩트하게 요약하여 나타내는 대표적인 방법으로 파라미터 가족(Parametric family, 예: 가우시안 분포)을 정의하고, 8.3절에서 배운 최대 우도 추정(MLE)이나 최대 사후 확률 추정(MAP)을 활용하여 평균과 분산을 찾는 방식을 취합니다.

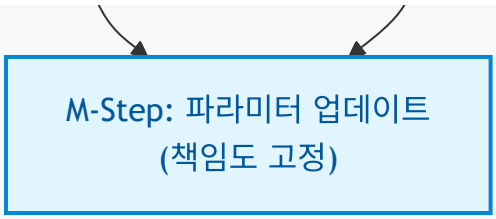
그러나 단일 가우시안 분포(Single Gaussian Distribution)는 단봉형(Unimodal) 대칭 구조만을 표현할 수 있으므로, 다봉형(Multimodal) 분포나 복잡한 군집 구조를 지닌 실제 데이터(Figure 11.1과 같은 비볼록성 분포)를 표현하기에는 모델링 역량이 크게 제한됩니다. 이러한 한계를 극복하기 위해, 복수 개의 단순 기본 분포들의 볼록 조합(Convex combination)으로 더 강력한 표현력을 제공하는 **혼합 모델(Mixture Models)**, 그중에서도 각 성분이 가우시안 분포인 **혼합 가우시안 모델(Gaussian Mixture Model, GMM)**의 매개변수를 추정하는 체계적인 방법론을 다룹니다.

GMM의 최대 우도 추정은 선형 회귀나 PCA와 달리 대수적으로 닫힌 형태의 해(Closed-form solution)를 얻을 수 없으며, 매개변수 간의 상호 의존 관계를 유도한 뒤 반복적인 최적화를 수행하는 **기댓값 극대화(Expectation-Maximization, EM) 알고리즘**을 통해 수치적으로 수렴시킵니다.

[시각 자료] 혼합 가우시안 모델(GMM) 및 EM 알고리즘의 수학적 관계도

GMM의 수학적 정의부터 시작하여, 우도 함수의 한계로 인한 EM 알고리즘 유도, 그리고 잠재 변수 관점과의 동치성을 보여주는 마인드맵입니다.


혼합 가우시안 모델
(Gaussian Mixture Model)
K-means 군집화
(Hard Assignment)
잠재 변수 관점
z_n ∈ {0,1}^K (One-hot)
GMM 밀도 추정
(Soft Assignment)
z 주변화 (Marginalization)
p(x|θ) = Σ_z p(x,z|θ)
로그 우도 함수
log Σ_k π_k N(x|μ_k, Σ_k)
로그 내부에 합이 존재
닫힌 형태의 해 존재 불가
EM 알고리즘
(Expectation-Maximization)
E-Step: 책임도 r_nk 계산
(현재 파라미터 고정)
책임도 (Responsibility)
r_nk: 성분 k가 n을 생성했
을 사후확률



11.1 혼합 가우시안 모델 (Gaussian Mixture Model)

수학적으로 **혼합 모델(Mixture Model)**은 K개의 단순 기본 분포(Base distributions) $p_k(\mathbf{x})$의 **볼록 조합(Convex combination)**으로 전체 분포 $p(\mathbf{x})$를 구성합니다.

$$p(\mathbf{x}) = \sum_{k=1}^{K} \pi_k p_k(\mathbf{x}) \tag{11.1}$$

이때 혼합 계수 혹은 **혼합 가중치(Mixture weights)** π_k는 확률의 공리를 만족해야 하므로 다음의 제약 조건을 따릅니다.

$$0 \leq \pi_k \leq 1, \quad \sum_{k=1}^{K} \pi_k = 1 \tag{11.2}$$

기본 성분 분포 $p_k(\mathbf{x})$로서 가우시안 분포 $\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$를 선택한 것이 바로 **혼합 가우시안 모델(Gaussian Mixture Model, GMM)**입니다. GMM의 확률 밀도 함수는 다음과 같이 정의됩니다.

$$p(\mathbf{x}|\boldsymbol{\theta}) = \sum_{k=1}^{K} \pi_k \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \tag{11.3}$$

여기서 전체 매개변수 집합 $\boldsymbol{\theta}$는 각 성분의 가중치, 평균, 공분산 행렬들의 모임입니다.

$$\boldsymbol{\theta} := \{\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k, \pi_k : k = 1, \dots, K\}$$

GMM은 각각의 가우시안 성분들이 결합하여 단일 가우시안보다 훨씬 복잡하고 비대칭적인 다봉형 분포를 정밀하게 표현할 수 있게 합니다.

11.2 최대 우도를 통한 매개변수 학습 (Parameter Learning via Maximum Likelihood)

독립항등분포(i.i.d.) 가정에 기초하여 크기가 N인 데이터셋 $X = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$이 주어졌을 때, GMM의 우도 함수(Likelihood function) $p(X|\boldsymbol{\theta})$는 다음과 같이 개별 우도 항들의 곱으로 분해됩니다.

$$p(X|\boldsymbol{\theta}) = \prod_{n=1}^{N} p(\mathbf{x}_n|\boldsymbol{\theta}) = \prod_{n=1}^{N} \sum_{k=1}^{K} \pi_k \mathcal{N}(\mathbf{x}_n|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \tag{11.9}$$

양변에 자연로그를 취하여 **로그 우도 함수(Log-likelihood function) $\mathcal{L}$**을 도출합니다.

$$\mathcal{L}(\boldsymbol{\theta}) = \log p(X|\boldsymbol{\theta}) = \sum_{n=1}^{N} \log \left(\sum_{k=1}^{K} \pi_k \mathcal{N}(\mathbf{x}_n|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right) \tag{11.10}$$

닫힌 형태 해(Closed-form solution)가 존재하지 않는 이유

단일 가우시안 모델의 경우(즉, $K = 1$), 로그 함수가 지수 분포족인 가우시안의 지수 항과 바로 결합하여 로그 기호가 덧셈 연산 내부로 스며들 수 있습니다.

$$\log \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = -\frac{D}{2}\log(2\pi) - \frac{1}{2}\log\det(\boldsymbol{\Sigma}) - \frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu}) \tag{11.11}$$

이 경우 목적 함수가 이차 형식(Quadratic form)이 되므로, $\boldsymbol{\mu}$와 $\boldsymbol{\Sigma}$에 대해 미분하여 0으로 두는 단순 연산만으로 대수적인 닫힌 해를 쉽게 얻을 수 있습니다 (8장 참고).

반면 GMM ($K \geq 2$)의 로그 우도 함수 (11.10) 식에서는 **로그 기호 바로 오른쪽에 K개 성분의 덧셈 기호($\sum_{k=1}^{K}$)가 가로막고 있습니다.** 로그 함수는 덧셈에 대해 선형성을 가지지 않으므로($\log(a+b) \neq \log a + \log b$), 로그 기호를 덧셈 안으로 전개할 수 없습니다.

따라서 미분을 수행할 때 체인 룰(Chain rule)에 의해 분모에 복잡한 가중합 $\sum_j \pi_j \mathcal{N}(\mathbf{x}_n|\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)$이 위치하게 되고, 이는 모든 파라미터들이 고도로 얽혀 있는 복잡한 연립 방정식을 형성합니다. 이로 인해 분석적 기법(Analytic method)으로 한 번에 전역 최적해를 연산하는 것은 대수적으로 불가능하며, 수치적인 반복 갱신(Iterative update) 기법이 강제됩니다.

최적 조건의 정식화를 위해 목적 함수 $\mathcal{L}$에 대한 각 매개변수의 그레이디언트(Gradient)가 영벡터가 되는 필요조건을 수립합니다.

$$\frac{\partial \mathcal{L}}{\partial \boldsymbol{\mu}_k} = \mathbf{0}^\top, \quad \frac{\partial \mathcal{L}}{\partial \boldsymbol{\Sigma}_k} = \mathbf{0}, \quad \frac{\partial \mathcal{L}}{\partial \pi_k} = 0 \tag{11.12-11.14}$$

임의의 파라미터 $\boldsymbol{\theta}$에 대해 로그 우도 미분 구조를 전개하면 다음과 같은 형태가 요구됩니다.

$$\frac{\partial \log p(\mathbf{x}_n|\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \frac{1}{p(\mathbf{x}_n|\boldsymbol{\theta})} \frac{\partial p(\mathbf{x}_n|\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \tag{11.15}$$

여기서 분모의 역수 항은 다음과 같습니다.

$$\frac{1}{p(\mathbf{x}_n|\boldsymbol{\theta})} = \frac{1}{\sum_{j=1}^{K} \pi_j \mathcal{N}(\mathbf{x}_n|\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} \tag{11.16}$$

이 구조에서 핵심 매개변수 갱신 가중치 역할을 하는 **책임도(Responsibility)**를 정의합니다.

11.2.1 책임도 (Responsibilities)

n번째 데이터 포인트 $\mathbf{x}_n$에 대해 k번째 가우시안 성분이 가지는 사후 점유 확률을 **책임도 r_{nk}**라고 정의합니다.

$$r_{nk} := \frac{\pi_k \mathcal{N}(\mathbf{x}_n|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^{K} \pi_j \mathcal{N}(\mathbf{x}_n|\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} \tag{11.17}$$

이 값은 해당 성분이 가지는 우도값 $\pi_k \mathcal{N}(\mathbf{x}_n|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$의 상대적인 크기에 비례합니다.

- **확률 벡터적 성질**: 개별 데이터 포인트 n에 대해 책임도 벡터 $\mathbf{r}_n := [r_{n1}, \ldots, r_{nK}]^\top \in \mathbb{R}^K$는 성분이 모두 양수이고 합이 1인 정규화된 확률 분포(Probability vector)를 이룹니다.

$$\sum_{k=1}^{K} r_{nk} = 1, \quad r_{nk} \geq 0$$

- **부드러운 할당 (Soft assignment)**: 클러스터링 관점에서 이 확률 벡터는 데이터를 하나의 성분에 무조건 할당하는 '단단한 할당(Hard assignment)' 대신, 여러 성분에 확률적 무게를 나누어 배정하는 '부드러운 할당'의 성격을 갖습니다.
- **물리적 해석 (Gibbs/Boltzmann 분포)**: 통계물리학 관점에서 책임도 수식은 상태 에너지와 온도가 가미된 Gibbs 혹은 Boltzmann 분포의 수학적 구조와 일치합니다. 즉, 각 성분 가우시안과의 마할라노비스 거리(Mahalanobis distance) 제곱이 상태 에너지 역할을 하고, 정규화 분모는 분배 함수(Partition function) 역할을 하여 에너지 상태에 따라 확률 질량을 분배하는 것으로 해석할 수 있습니다.

11.2.2 평균의 갱신 (Updating the Means)

정리 11.1 (GMM 평균 갱신 공식)

책임도 r_{nk}가 주어진 상태에서 로그 우도를 극대화하는 GMM 평균 매개변수 $\boldsymbol{\mu}_k$의 최적 갱신값 $\boldsymbol{\mu}_k^{\text{new}}$는 다음과 같습니다.

$$\boldsymbol{\mu}_k^{\text{new}} = \frac{\sum_{n=1}^{N} r_{nk}\mathbf{x}_n}{\sum_{n=1}^{N} r_{nk}} \tag{11.20}$$

증명

로그 우도 함수 $\mathcal{L}$을 평균 벡터 $\boldsymbol{\mu}_k$에 대해 편미분해 봅시다. $p(\mathbf{x}_n|\boldsymbol{\theta})$의 합 기호 내에서 오직 k번째 성분만이 $\boldsymbol{\mu}_k$에 의존하므로,

$$\frac{\partial p(\mathbf{x}_n|\boldsymbol{\theta})}{\partial \boldsymbol{\mu}_k} = \frac{\partial}{\partial \boldsymbol{\mu}_k} \sum_{j=1}^{K} \pi_j \mathcal{N}(\mathbf{x}_n|\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j) = \pi_k \frac{\partial \mathcal{N}(\mathbf{x}_n|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\partial \boldsymbol{\mu}_k} \tag{11.21a}$$

벡터 미분 공식 $\frac{\partial}{\partial \mathbf{s}} \exp(-\frac{1}{2}(\mathbf{y}-\mathbf{s})^\top \mathbf{W}(\mathbf{y}-\mathbf{s})) = \exp(\dots)(\mathbf{y}-\mathbf{s})^\top \mathbf{W}$를 적용하면,

$$\frac{\partial \mathcal{N}(\mathbf{x}_n|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\partial \boldsymbol{\mu}_k} = (\mathbf{x}_n - \boldsymbol{\mu}_k)^\top \boldsymbol{\Sigma}_k^{-1} \mathcal{N}(\mathbf{x}_n|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

따라서,

$$\frac{\partial p(\mathbf{x}_n|\boldsymbol{\theta})}{\partial \boldsymbol{\mu}_k} = \pi_k (\mathbf{x}_n - \boldsymbol{\mu}_k)^\top \boldsymbol{\Sigma}_k^{-1} \mathcal{N}(\mathbf{x}_n|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \tag{11.21b}$$

이를 로그 우도의 합 미분 식 (11.15)에 대입합니다.

$$\frac{\partial \mathcal{L}}{\partial \boldsymbol{\mu}_k} = \sum_{n=1}^{N} \frac{1}{p(\mathbf{x}_n|\boldsymbol{\theta})} \frac{\partial p(\mathbf{x}_n|\boldsymbol{\theta})}{\partial \boldsymbol{\mu}_k} = \sum_{n=1}^{N} \frac{\pi_k \mathcal{N}(\mathbf{x}_n|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^{K} \pi_j \mathcal{N}(\mathbf{x}_n|\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} (\mathbf{x}_n - \boldsymbol{\mu}_k)^\top \boldsymbol{\Sigma}_k^{-1} \tag{11.22b}$$

가운데 분수 항을 앞서 정의한 책임도 r_{nk}로 치환하여 정리합니다.

$$\frac{\partial \mathcal{L}}{\partial \boldsymbol{\mu}_k} = \sum_{n=1}^{N} r_{nk} (\mathbf{x}_n - \boldsymbol{\mu}_k)^\top \boldsymbol{\Sigma}_k^{-1} \tag{11.22c}$$

최적점에서는 이 임계 편미분 벡터의 값이 영벡터 $\mathbf{0}^\top$가 되어야 합니다. 우도 극대화 조건 하의 평균 갱신값을 $\boldsymbol{\mu}_k^{\text{new}}$라 할 때, 정칙 행렬(Regular matrix)인 $\boldsymbol{\Sigma}_k^{-1}$을 우측에 곱하는 연산은 임계 조건에 영향을 주지 않으므로 식은 다음과 같이 정리됩니다.

$$\sum_{n=1}^{N} r_{nk}(\mathbf{x}_n - \boldsymbol{\mu}_k^{\text{new}})^\top = \mathbf{0}^\top \implies \sum_{n=1}^{N} r_{nk}\mathbf{x}_n^\top = \sum_{n=1}^{N} r_{nk}(\boldsymbol{\mu}_k^{\text{new}})^\top$$

양변을 전치하고 $\boldsymbol{\mu}_k^{\text{new}}$에 대해 정리하면,

$$\boldsymbol{\mu}_k^{\text{new}} = \frac{\sum_{n=1}^{N} r_{nk}\mathbf{x}_n}{\sum_{n=1}^{N} r_{nk}} = \frac{1}{N_k}\sum_{n=1}^{N} r_{nk}\mathbf{x}_n \tag{11.23}$$

여기서 N_k는 k번째 가우시안 성분이 전체 데이터셋에 대해 짊어지는 책임도의 총량입니다.

$$N_k := \sum_{n=1}^{N} r_{nk} \tag{11.24}$$

이로써 정리 11.1의 증명이 완료됩니다.

이 식은 가우시안 성분 k의 평균 $\boldsymbol{\mu}_k$가 데이터 포인트 $\mathbf{x}_n$들을 책임도 r_{nk}의 강도로 끌어당기는 물리적 중력 모델로 직관화될 수 있습니다.

11.2.3 공분산의 갱신 (Updating the Covariances)

정리 11.2 (GMM 공분산 갱신 공식)

GMM의 공분산 행렬 $\boldsymbol{\Sigma}_k$의 최적 갱신값 $\boldsymbol{\Sigma}_k^{\text{new}}$는 다음과 같습니다.

$$\boldsymbol{\Sigma}_k^{\text{new}} = \frac{1}{N_k}\sum_{n=1}^{N} r_{nk}(\mathbf{x}_n - \boldsymbol{\mu}_k)(\mathbf{x}_n - \boldsymbol{\mu}_k)^\top \tag{11.30}$$

증명

로그 우도 함수 $\mathcal{L}$을 공분산 행렬 $\boldsymbol{\Sigma}_k$에 대해 편미분하기 위해 개별 항들을 분석합니다.

$$\frac{\partial \mathcal{L}}{\partial \boldsymbol{\Sigma}_k} = \sum_{n=1}^{N} \frac{1}{p(\mathbf{x}_n|\boldsymbol{\theta})} \frac{\partial p(\mathbf{x}_n|\boldsymbol{\theta})}{\partial \boldsymbol{\Sigma}_k} \tag{11.31}$$

마찬가지로 오직 k번째 성분만이 $\boldsymbol{\Sigma}_k$에 의존하므로,

$$\frac{\partial p(\mathbf{x}_n|\boldsymbol{\theta})}{\partial \boldsymbol{\Sigma}_k} = \pi_k \frac{\partial \mathcal{N}(\mathbf{x}_n|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\partial \boldsymbol{\Sigma}_k} \tag{11.32a}$$

가우시안 분포의 명시적 공식인 $\mathcal{N}(\mathbf{x}_n|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) = (2\pi)^{-\frac{D}{2}}\det(\boldsymbol{\Sigma}_k)^{-\frac{1}{2}}\exp\left(-\frac{1}{2}(\mathbf{x}_n - \boldsymbol{\mu}_k)^\top\boldsymbol{\Sigma}_k^{-1}(\mathbf{x}_n - \boldsymbol{\mu}_k)\right)$을 대입하고 곱의 미분법(Product rule)을 적용합니다.

$$\frac{\partial \mathcal{N}}{\partial \boldsymbol{\Sigma}_k} = (2\pi)^{-\frac{D}{2}}\left[\frac{\partial \det(\boldsymbol{\Sigma}_k)^{-\frac{1}{2}}}{\partial \boldsymbol{\Sigma}_k}\exp(\dots) + \det(\boldsymbol{\Sigma}_k)^{-\frac{1}{2}}\frac{\partial \exp(\dots)}{\partial \boldsymbol{\Sigma}_k}\right] \tag{11.32c}$$

여기에 행렬 미분 공식 (5.101) $\frac{\partial \det(\mathbf{A})^r}{\partial \mathbf{A}} = r\det(\mathbf{A})^r \mathbf{A}^{-1}$과 (5.103) $\frac{\partial \mathbf{a}^\top \mathbf{X}^{-1}\mathbf{a}}{\partial \mathbf{X}} = -\mathbf{X}^{-1}\mathbf{a}\mathbf{a}^\top\mathbf{X}^{-1}$을 도입합니다.

$$\frac{\partial \det(\boldsymbol{\Sigma}_k)^{-\frac{1}{2}}}{\partial \boldsymbol{\Sigma}_k} = -\frac{1}{2}\det(\boldsymbol{\Sigma}_k)^{-\frac{1}{2}}\boldsymbol{\Sigma}_k^{-1} \tag{11.33}$$

$$\frac{\partial}{\partial \boldsymbol{\Sigma}_k}\left(-\frac{1}{2}(\mathbf{x}_n-\boldsymbol{\mu}_k)^\top\boldsymbol{\Sigma}_k^{-1}(\mathbf{x}_n-\boldsymbol{\mu}_k)\right) = \frac{1}{2}\boldsymbol{\Sigma}_k^{-1}(\mathbf{x}_n-\boldsymbol{\mu}_k)(\mathbf{x}_n-\boldsymbol{\mu}_k)^\top\boldsymbol{\Sigma}_k^{-1} \tag{11.34}$$

이 두 미분식을 곱의 미분 전개식에 합산하여 묶어줍니다.

$$\frac{\partial p(\mathbf{x}_n|\boldsymbol{\theta})}{\partial \boldsymbol{\Sigma}_k} = \pi_k \mathcal{N}(\mathbf{x}_n|\boldsymbol{\mu}_k,\boldsymbol{\Sigma}_k)\left[-\frac{1}{2}\boldsymbol{\Sigma}_k^{-1} + \frac{1}{2}\boldsymbol{\Sigma}_k^{-1}(\mathbf{x}_n-\boldsymbol{\mu}_k)(\mathbf{x}_n-\boldsymbol{\mu}_k)^\top\boldsymbol{\Sigma}_k^{-1}\right] \tag{11.35}$$

이를 (11.31) 식에 결합하여 로그 우도의 공분산 미분을 도출합니다.

$$\frac{\partial \mathcal{L}}{\partial \boldsymbol{\Sigma}_k} = \sum_{n=1}^{N}\frac{\pi_k\mathcal{N}(\mathbf{x}_n|\boldsymbol{\mu}_k,\boldsymbol{\Sigma}_k)}{p(\mathbf{x}_n|\boldsymbol{\theta})}\left[-\frac{1}{2}\left(\boldsymbol{\Sigma}_k^{-1} - \boldsymbol{\Sigma}_k^{-1}(\mathbf{x}_n-\boldsymbol{\mu}_k)(\mathbf{x}_n-\boldsymbol{\mu}_k)^\top\boldsymbol{\Sigma}_k^{-1}\right)\right] \tag{11.36b}$$

앞부분의 분수 결합식을 책임도 r_{nk}로 변경합니다.

$$\frac{\partial \mathcal{L}}{\partial \boldsymbol{\Sigma}_k} = -\frac{1}{2}\sum_{n=1}^{N} r_{nk}\left[\boldsymbol{\Sigma}_k^{-1} - \boldsymbol{\Sigma}_k^{-1}(\mathbf{x}_n-\boldsymbol{\mu}_k)(\mathbf{x}_n-\boldsymbol{\mu}_k)^\top\boldsymbol{\Sigma}_k^{-1}\right] \tag{11.36c}$$

이 편미분 행렬을 영행렬 $\mathbf{0}$으로 설정하는 기하학적 임계점 조건을 정식화합니다.

$$-\frac{1}{2}\boldsymbol{\Sigma}_k^{-1}\sum_{n=1}^{N} r_{nk} + \frac{1}{2}\boldsymbol{\Sigma}_k^{-1}\left(\sum_{n=1}^{N} r_{nk}(\mathbf{x}_n-\boldsymbol{\mu}_k)(\mathbf{x}_n-\boldsymbol{\mu}_k)^\top\right)\boldsymbol{\Sigma}_k^{-1} = \mathbf{0} \tag{11.36d}$$

양변의 왼쪽에 $2\boldsymbol{\Sigma}_k$를 곱하여 정리합니다.

$$-\left(\sum_{n=1}^{N} r_{nk}\right)\mathbf{I} + \left(\sum_{n=1}^{N} r_{nk}(\mathbf{x}_n-\boldsymbol{\mu}_k)(\mathbf{x}_n-\boldsymbol{\mu}_k)^\top\right)\boldsymbol{\Sigma}_k^{-1} = \mathbf{0}$$

$$\implies N_k\mathbf{I} = \left(\sum_{n=1}^{N} r_{nk}(\mathbf{x}_n-\boldsymbol{\mu}_k)(\mathbf{x}_n-\boldsymbol{\mu}_k)^\top\right)\boldsymbol{\Sigma}_k^{-1} \tag{11.37b}$$

양변의 오른쪽에 새로운 갱신값 $\boldsymbol{\Sigma}_k^{\text{new}}$를 행렬 곱하면 최적화된 공분산 갱신 공식이 명확하게 도출됩니다.

$$\boldsymbol{\Sigma}_k^{\text{new}} = \frac{1}{N_k}\sum_{n=1}^{N} r_{nk}(\mathbf{x}_n-\boldsymbol{\mu}_k)(\mathbf{x}_n-\boldsymbol{\mu}_k)^\top \tag{11.38}$$

이로써 정리 11.2가 대수적으로 엄밀하게 증명됩니다.

이는 각 데이터가 평균으로부터 떨어진 외적(Outer product) 분산 행렬에 책임도를 곱하여 가중 평균한 경험적 공분산의 형태로 직관화됩니다.

11.2.4 혼합 가중치의 갱신 (Updating the Mixture Weights)

정리 11.3 (GMM 혼합 가중치 갱신 공식)

제약 조건 $\sum_{k=1}^{K} \pi_k = 1$ 하에서 로그 우도를 최대화하는 혼합 가중치 π_k^{new}는 다음과 같습니다.

$$\pi_k^{\text{new}} = \frac{N_k}{N} \tag{11.42}$$

증명

혼합 가중치 π_k는 단순 자유 매개변수가 아니며, 총합이 1이 되어야 하고 음수가 아니어야 한다는 강력한 등식 제약 조건을 내포하고 있습니다. 따라서 7.2절에서 다룬 **라그랑주 승수법(Lagrange Multipliers)**을 적용하여 제약 제어 목적 함수를 설계해야 합니다. 등식 제약 조건 $\sum_{k=1}^{K} \pi_k - 1 = 0$에 대한 라그랑주 승수 λ를 도입하여 라그랑지안(Lagrangian) $\mathcal{G}$를 구성합니다.

$$\mathcal{G}(\boldsymbol{\pi}, \lambda) = \mathcal{L}(\boldsymbol{\theta}) + \lambda \left(\sum_{k=1}^{K} \pi_k - 1 \right) \tag{11.43a}$$

$$\mathcal{G}(\boldsymbol{\pi}, \lambda) = \sum_{n=1}^{N} \log \left(\sum_{j=1}^{K} \pi_j \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j) \right) + \lambda \left(\sum_{k=1}^{K} \pi_k - 1 \right) \tag{11.43b}$$

이 라그랑지안을 특정 가중치 π_k에 대해 편미분합니다.

$$\frac{\partial \mathcal{G}}{\partial \pi_k} = \sum_{n=1}^{N} \frac{\mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^{K} \pi_j \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} + \lambda \tag{11.44a}$$

수식 전개를 위해 첫 번째 항의 분자와 분모에 π_k를 곱해 줍니다.

$$\frac{\partial \mathcal{G}}{\partial \pi_k} = \frac{1}{\pi_k} \sum_{n=1}^{N} \frac{\pi_k \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^{K} \pi_j \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} + \lambda = \frac{1}{\pi_k} \sum_{n=1}^{N} r_{nk} + \lambda = \frac{N_k}{\pi_k} + \lambda \tag{11.44b}$$

최적점에서는 이 그레이디언트 값과 라그랑주 승수 편미분 값이 모두 0이 되어야 합니다.

$$\frac{N_k}{\pi_k} + \lambda = 0 \implies \pi_k = -\frac{N_k}{\lambda} \tag{11.46}$$

이 식을 제약 조건 $\sum_{k=1}^{K} \pi_k = 1$에 대입하여 λ를 풀어냅니다.

$$\sum_{k=1}^{K} \left(-\frac{N_k}{\lambda} \right) = 1 \implies -\frac{1}{\lambda} \sum_{k=1}^{K} N_k = 1$$

이때 전체 성분에 대한 책임도 총량의 합은 다음과 같이 총 데이터 수 N과 대수적으로 동치입니다.

$$\sum_{k=1}^{K} N_k = \sum_{k=1}^{K} \sum_{n=1}^{N} r_{nk} = \sum_{n=1}^{N} \sum_{k=1}^{K} r_{nk} = \sum_{n=1}^{N} 1 = N$$

따라서,

$$-\frac{N}{\lambda} = 1 \implies \lambda = -N \tag{11.48}$$

구해진 $\lambda = -N$을 원래의 (11.46) 식에 대입하면 최적의 가중치 갱신 공식이 엄밀하게 유도됩니다.

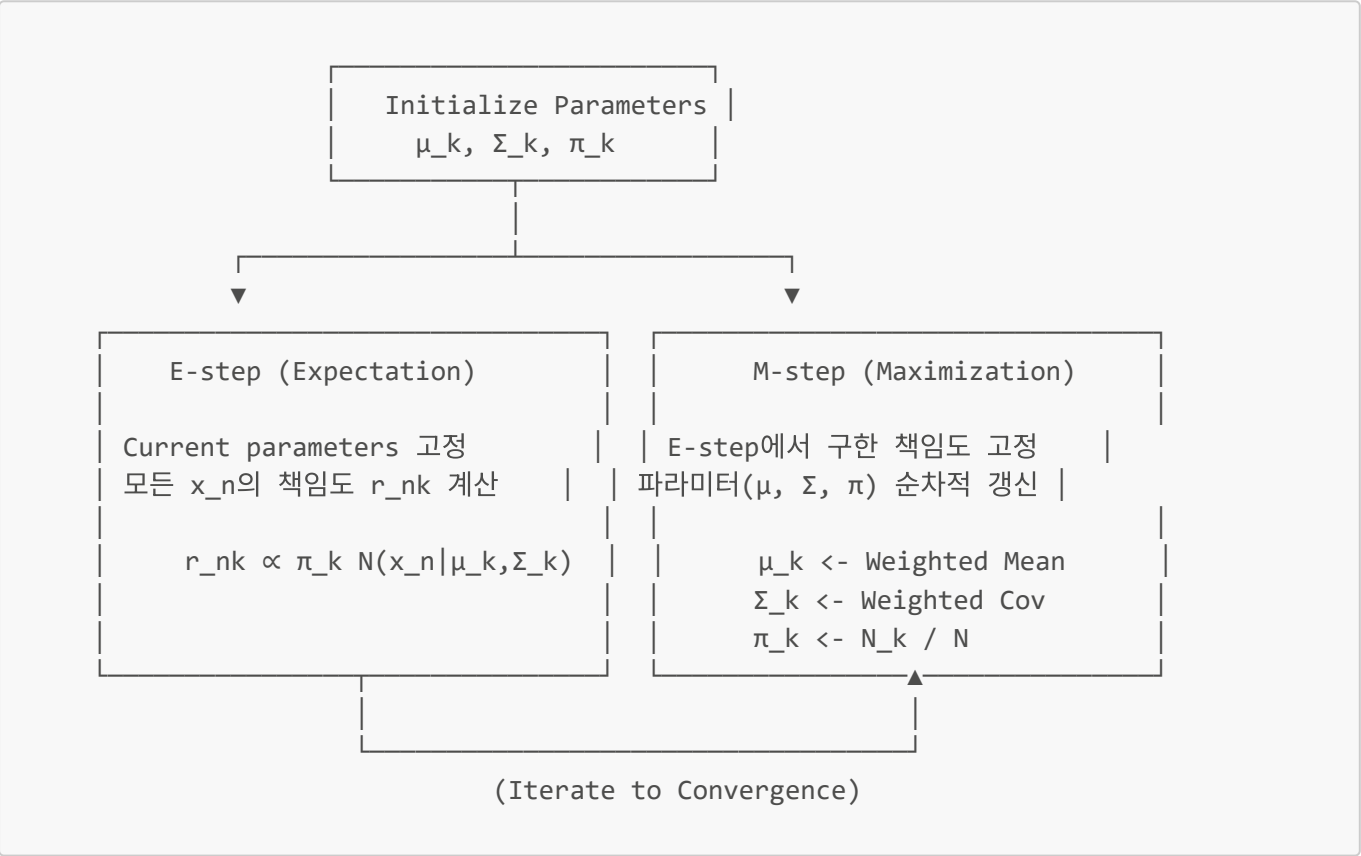
$$\pi_k^{\text{new}} = \frac{N_k}{N} \tag{11.49}$$

이로써 정리 11.3의 증명이 완료됩니다.

각 가우시안 성분의 가중치는 해당 성분이 데이터들에 대해 행사한 총 책임도 분율(N_k/N)로 최적화됨을 알 수 있습니다.

11.3 EM 알고리즘 (Expectation-Maximization Algorithm)

앞서 도출한 모든 매개변수 업데이트 식(평균, 공분산, 가중치)이 우변의 책임도 r_{nk}에 고도로 의존하고 있으며, 책임도 역시 좌변의 모든 매개변수들의 복잡한 함수라는 딜레마(Mutual dependency)에 봉착합니다. 이를 조율하기 위해 두 단계를 교차 갱신하는 **기댓값 극대화(EM) 알고리즘**을 도입합니다.



1. **초기화(Initialization)**: 매개변수 $\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k, \pi_k$의 초기값을 임의로 설정합니다 (통상 K-means 결과 활용).
2. **기댓값 단계 (E-step)**: 현재 설정된 모델 파라미터를 고정한 상태에서, 모든 데이터 포인트 $\mathbf{x}_n$에 대해 각 성분 k가 가지는 책임도 r_{nk}를 계산합니다.

$$r_{nk} = \frac{\pi_k \mathcal{N}(\mathbf{x}_n|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^{K} \pi_j \mathcal{N}(\mathbf{x}_n|\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} \tag{11.53}$$

3. **극대화 단계 (M-step)**: E-step에서 계산해 둔 책임도 r_{nk} 값을 상수처럼 고정한 상태에서, 로그 우도를 최대화하는 신규 파라미터 값들을 계산합니다.

$$\boldsymbol{\mu}_k^{\text{new}} = \frac{1}{N_k} \sum_{n=1}^{N} r_{nk} \mathbf{x}_n \tag{11.54}$$

$$\boldsymbol{\Sigma}_k^{\text{new}} = \frac{1}{N_k}\sum_{n=1}^{N} r_{nk}(\mathbf{x}_n - \boldsymbol{\mu}_k^{\text{new}})(\mathbf{x}_n - \boldsymbol{\mu}_k^{\text{new}})^\top \tag{11.55}$$

$$\pi_k^{\text{new}} = \frac{N_k}{N} \tag{11.56}$$

4. **수렴 판정(Convergence check)**: 매 반복 주기마다 로그 우도 $\mathcal{L}$을 모니터링하여 변동량이 임계값 이하로 작아지면 수렴한 것으로 판단하여 종료합니다. EM 알고리즘의 매 단계는 로그 우도 함수를 단조 증가(Monotonically increase)시킴이 증명되어 있습니다.

11.4 잠재 변수 관점 (Latent-Variable Perspective)

GMM을 수학적으로 보다 엄밀하고 우아하게 정식화하는 방법은 관측되지 않는 숨겨진 변수인 **이산 잠재 변수(Discrete latent variable) $\mathbf{z}$**를 명시적으로 도입하는 것입니다. PCA가 연속적인 잠재 변수를 다룬 것과 달리, GMM은 이산적인 잠재 범주 변수를 다룹니다.

11.4.1 생성 프로세스 및 확률 모델 (Generative Process)

각 데이터 포인트 $\mathbf{x}$가 K개의 가우시안 중 정확히 단 하나의 가우시안 성분으로부터 생성되었다고 가정합시다. 이를 나타내기 위해 다음과 같은 성질을 갖는 **이진 지시 변수(Binary indicator variable) $\mathbf{z} \in \{0,1\}^K$**를 정의합니다.

$$\mathbf{z} = [z_1, \ldots, z_K]^\top \in \{0,1\}^K, \quad \sum_{k=1}^{K} z_k = 1$$

즉, $\mathbf{z}$는 단 하나의 원소만 1이고 나머지는 모두 0인 **원-핫 인코딩(One-hot encoding / 1-of-K representation)** 벡터입니다. 만약 k번째 가우시안에서 데이터가 생성되었다면 $z_k = 1$이 성립합니다.

- **조건부 데이터 생성 확률**: 잠재 지시 벡터의 k번째 원소가 1로 활성화되었을 때, 데이터가 관측될 조건부 분포는 해당 가우시안 성분을 따릅니다.

$$p(\mathbf{x}|z_k = 1) = \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \tag{11.58}$$

- **잠재 변수의 사전 분포 (Prior)**: 잠재 변수 $\mathbf{z}$ 자체에 대한 사전 확률은 혼합 가중치 벡터 $\boldsymbol{\pi}$로 주어지는 멀티누이(Multinoulli / Categorical) 분포를 따릅니다.

$$p(\mathbf{z}) = \boldsymbol{\pi} = [\pi_1, \ldots, \pi_K]^\top \implies p(z_k = 1) = \pi_k \tag{11.59-11.60}$$

- **조상 샘플링 (Ancestral Sampling)**: 이 생성 모델 관점(Figure 11.11의 그래픽 모델 참고)을 활용하면 복잡한 GMM 분포로부터 데이터를 매우 쉽게 샘플링할 수 있습니다.
  1. 사전 분포 $p(\mathbf{z})$로부터 카테고리 샘플 $\mathbf{z}^{(i)}$를 추출합니다 (특정 성분 k가 선택됨).
  2. 선택된 성분의 조건부 가우시안 분포 $p(\mathbf{x}|\mathbf{z}^{(i)})$로부터 데이터 관측값 $\mathbf{x}^{(i)}$를 추출합니다.

결합 확률 분포(Joint probability distribution) $p(\mathbf{x}, \mathbf{z})$는 확률의 곱셈 정리에 의해 사전 분포와 조건부 분포의 곱으로 완전하게 명시됩니다.

$$p(\mathbf{x}, z_k = 1) = p(\mathbf{x}|z_k = 1)p(z_k = 1) = \pi_k \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \tag{11.61}$$

이를 벡터 전체로 확장하면 다음과 같이 각 성분의 가중 가우시안 확률들의 모임이 됩니다.

$$p(\mathbf{x}, \mathbf{z}) = \begin{bmatrix} p(\mathbf{x}, z_1 = 1) \\ \vdots \\ p(\mathbf{x}, z_K = 1) \end{bmatrix} = \begin{bmatrix} \pi_1 \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_1) \\ \vdots \\ \pi_K \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_K, \boldsymbol{\Sigma}_K) \end{bmatrix} \tag{11.62}$$

11.4.2 우도 (Likelihood)

우리가 관측할 수 있는 것은 오직 관측 데이터 $\mathbf{x}$뿐이며 잠재 변수 $\mathbf{z}$는 관측 불가능하므로, 모델의 주변 우도(Marginal likelihood)를 구하기 위해 잠재 변수를 **주변화(Marginalization)**하여 제거해야 합니다.

$$p(\mathbf{x}|\boldsymbol{\theta}) = \sum_{\mathbf{z}} p(\mathbf{x}, \mathbf{z}|\boldsymbol{\theta}) = \sum_{\mathbf{z}} p(\mathbf{x}|\mathbf{z}, \boldsymbol{\theta}) p(\mathbf{z}|\boldsymbol{\theta}) \tag{11.63}$$

$\mathbf{z}$가 가질 수 있는 유효한 모든 상태(원-핫 벡터들)에 대해 합을 수행하는 것은 결국 1의 값을 가지는 인덱스 k를 1부터 K까지 순차적으로 대입하며 더하는 것과 대수적으로 일치합니다.

$$p(\mathbf{x}|\boldsymbol{\theta}) = \sum_{k=1}^{K} p(\mathbf{x}|z_k = 1, \boldsymbol{\theta}) p(z_k = 1|\boldsymbol{\theta}) = \sum_{k=1}^{K} \pi_k \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \tag{11.66b}$$

이 주변 우도 수식은 앞서 직관적으로 정의했던 GMM의 정의 식 (11.3)과 수학적으로 완벽하게 일치합니다. 즉, 잠재 변수 모델로 정식화하는 것과 원래의 혼합 모델 정의는 완벽한 동치 관계에 있습니다.

11.4.3 사후 분포 (Posterior Distribution)

베이즈 정리(Bayes' theorem)를 사용해 관측값 $\mathbf{x}$가 주어졌을 때 잠재 변수 $\mathbf{z}$의 조건부 사후 확률 $p(z_k = 1|\mathbf{x})$를 도출해 봅시다.

$$p(z_k = 1|\mathbf{x}) = \frac{p(z_k = 1) p(\mathbf{x}|z_k = 1)}{p(\mathbf{x})} = \frac{\pi_k \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^{K} \pi_j \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} \tag{11.69}$$

이 공식은 우리가 앞서 직관적으로 정의했던 **책임도 r_{nk}의 정의 식 (11.17)과 수학적으로 일치**합니다.

이로써 단순한 가중치 분율로 취급했던 책임도가 사실은 **"데이터 $\mathbf{x}$가 관측되었을 때, 이 데이터가 k번째 가우시안 성분으로부터 나왔을 사후 확률(Posterior probability)"**이라는 엄밀한 베이지안 수학적 정당성을 획득하게 됩니다.

11.4.4 전체 데이터셋으로의 확장 (Extension to a Full Dataset)

데이터셋 $X = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$의 각 개별 데이터 $\mathbf{x}_n$마다 고유한 독립적 잠재 변수 $\mathbf{z}_n = [z_{n1}, \dots, z_{nK}]^\top \in \{0, 1\}^K$이 매핑됩니다 (Figure 11.12 플레이트 표기법 참고).

사전 분포 $\boldsymbol{\pi}$는 모든 데이터 포인트가 공유하며, 각 데이터의 사후 분포 역시 베이즈 정리에 의해 동일하게 책임도 r_{nk}로 수렴합니다.

$$p(z_{nk} = 1|\mathbf{x}_n) = r_{nk} \tag{11.72b}$$

11.4.5 EM 알고리즘의 재해석 (EM Algorithm Revisited)

잠재 변수 관점에서 EM 알고리즘은 관측 불가능한 잠재 변수 $\mathbf{z}$에 대해 참 사후 분포 $p(\mathbf{z}|X, \boldsymbol{\theta}^{(t)})$를 가중치로 사용하는 로그 우도 함수의 기댓값을 정의하고 최적화하는 과정으로 해석됩니다.

E-step (Expectation)

현재 파라미터 $\boldsymbol{\theta}^{(t)}$ 하에서 잠재 변수 $\mathbf{z}$의 조건부 사후 분포에 대한 결합 로그 우도 $\log p(X, \mathbf{z}|\boldsymbol{\theta})$의 조건부 기댓값 함수 $Q(\boldsymbol{\theta}|\boldsymbol{\theta}^{(t)})$를 구성합니다.

$$Q(\boldsymbol{\theta}|\boldsymbol{\theta}^{(t)}) = \mathbb{E}_{\mathbf{z}|X,\boldsymbol{\theta}^{(t)}}\left[\log p(X, \mathbf{z}|\boldsymbol{\theta})\right] = \sum_{\mathbf{z}} p(\mathbf{z}|X, \boldsymbol{\theta}^{(t)}) \log p(X, \mathbf{z}|\boldsymbol{\theta}) \tag{11.73a-11.73b}$$

i.i.d. 조건 하에서 개별 데이터에 대해 합으로 정리하면 다음과 같습니다.

$$Q(\boldsymbol{\theta}|\boldsymbol{\theta}^{(t)}) = \sum_{n=1}^{N}\sum_{k=1}^{K} r_{nk}^{(t)} \left[\log \pi_k + \log \mathcal{N}(\mathbf{x}_n|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)\right]$$

M-step (Maximization)

이 기댓값 함수 Q를 최대로 만족하는 새로운 매개변수 $\boldsymbol{\theta}^{(t+1)}$을 선택합니다.

$$\boldsymbol{\theta}^{(t+1)} = \arg\max_{\boldsymbol{\theta}} Q(\boldsymbol{\theta}|\boldsymbol{\theta}^{(t)})$$

이 최적화 과정은 라그랑주 제약을 수반하는 미분 계산을 거쳐 앞서 11.2절에서 유도한 갱신 식들과 완벽히 일치하게 됩니다.

11.5 추가 정보 및 관련 방법론 (Further Reading)

K-means와의 관계 (Hard vs. Soft Clustering)

GMM은 널리 알려진 군집화 알고리즘인 K-means와 수학적으로 매우 깊은 유대 관계를 맺고 있습니다. GMM의 각 성분의 평균 $\boldsymbol{\mu}_k$를 군집의 중심점으로 바라볼 수 있습니다.

- **공분산 행렬의 축소**: 만약 모든 가우시안 성분의 공분산 행렬을 단위 행렬의 상수배 형태인 $\sigma^2\mathbf{I}$로 통일하고 분산 $\sigma^2 \to 0$으로 수축시킨다면, 책임도 r_{nk}는 가장 가까운 중심점에 대해서만 1을 가지고 나머지는 모두 0이 되는 원-핫 지시 함수(Indicator function)로 변환됩니다.
- **의사 결정 방식의 차이**: K-means는 가장 가까운 중심점에 데이터를 무조건 100% 매핑하는 **단단한 결정(Hard assignment)** 방식을 채택하는 반면, GMM은 데이터의 밀도 경계면에서 확률적 비율로 부드럽게 점유율을 나누는 **부드러운 결정(Soft assignment)** 방식을 취해 기하학적 형태 유연성이 훨씬 뛰어납니다.

최대 우도 추정의 한계: 특이점 및 과적합 (Singularity & Overfitting)

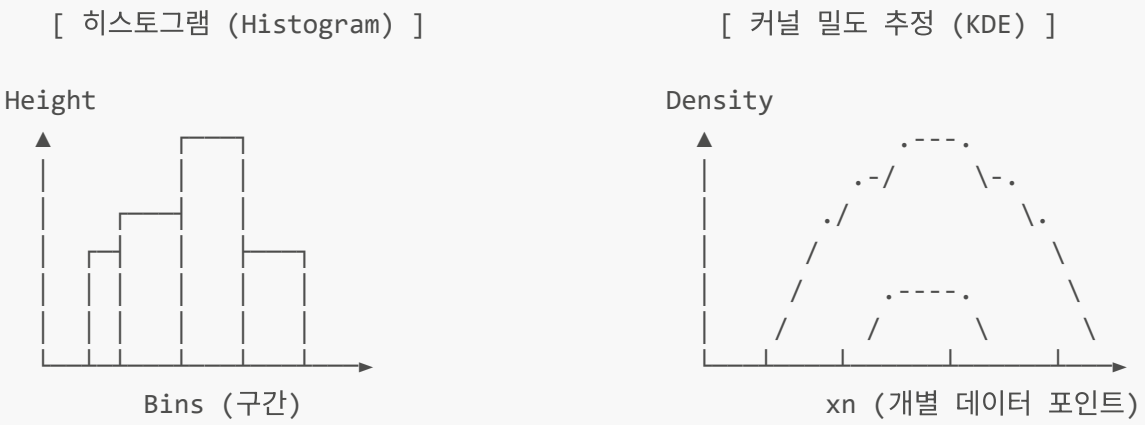
GMM을 EM을 통한 최대 우도법으로 학습할 때 다음과 같은 두 가지 심각한 수학적 결함이 발생할 수 있습니다.

1. **특이점 문제 (Singularity / Likelihood Collapse)**: 특정 가우시안 성분 k의 평균 $\boldsymbol{\mu}_k$가 우연히 단 하나의 데이터 포인트 $\mathbf{x}_n$의 값과 정확히 일치하고($\boldsymbol{\mu}_k = \mathbf{x}_n$), 해당 성분의 분산 σ_k^2이 0으로 수축하게 되면($\sigma_k^2 \to 0$), 해당 데이터에 대한 우도값이 무한대(∞)로 치솟아 전체 우도 합이 발산하게 됩니다. 이는 수치 연산 장치에서 오버플로우를 발생시키는 요인입니다.

2. **베이지안 기법의 대안**: 이 문제를 해결하기 위해 매개변수 자체에 Prior를 설정하는 베이지안 GMM(Bayesian GMM) 기법이 활용됩니다. 매개변수 $\boldsymbol{\mu}, \boldsymbol{\Sigma}, \boldsymbol{\pi}$에 디리클레(Dirichlet) 및 위샤트(Wishart) 등의 켤레 사전 분포(Conjugate Prior)를 도입하면 특이점 발산을 방지할 수 있습니다. 다만 이 경우 사후 분포가 더 이상 닫힌 형태로 계산되지 않으므로, **변분 추론(Variational Inference, VI)** 등의 근사 기법을 이용하여 근사 사후 분포를 갱신해야 합니다.

비모수 밀도 추정 (Non-parametric Density Estimation)

GMM은 K라는 고정된 성분의 개수를 가정하는 모수적 기법입니다. 이와 대조적으로 사전에 데이터 분포 모양을 제한하지 않는 대표적인 **비모수적 밀도 추정(Non-parametric density estimation)** 방법론으로 히스토그램과 커널 밀도 추정이 존재합니다.



1. 히스토그램 (Histogram)

가장 역사가 길고 직관적인 비모수적 추정법입니다. 데이터를 특정 간격의 격자 구간(Bin)으로 분할하고, 각 구간 안에 떨어지는 데이터 개수를 카운트하여 그 높이를 기둥 형태로 시각화합니다.

- **한계**: 구간의 경계면에서 확률 밀도가 뚝뚝 끊기는 불연속성을 나타내며, 격자 크기(Bin width) 및 격자 원점 설정에 따라 분포 형태가 극도로 왜곡되는 한계가 있습니다.

2. 커널 밀도 추정 (Kernel Density Estimation, KDE)

히스토그램의 불연속성 문제를 해결하기 위해, 개별 데이터 포인트 $\mathbf{x}_n$ 마다 미분 가능하고 부드러운 대칭 형태의 **커널 함수(Kernel function) $k(\cdot)$**를 얹은 뒤 이들의 평균합으로 전체 밀도를 구성합니다.

$$p(\mathbf{x}) = \frac{1}{Nh^D} \sum_{n=1}^{N} k\left(\frac{\mathbf{x} - \mathbf{x}_n}{h} \right) \tag{11.74}$$

- **커널 제약 조건**: 커널 함수 $k(\mathbf{u})$는 수학적으로 모든 영역에서 음수가 아니어야 하며, 전체 공간에 대한 적분값이 1이어야 밀도 함수의 조건을 충족합니다.

$$k(\mathbf{u}) \geq 0, \quad \int_{\mathbb{R}^D} k(\mathbf{u}) d\mathbf{u} = 1$$

대표적으로 가우시안 커널 $k(\mathbf{u}) = (2\pi)^{-\frac{D}{2}} \exp(-\frac{1}{2}\|\mathbf{u}\|^2)$이 널리 쓰입니다.

- **대역폭(Bandwidth)** h: 대역폭 파라미터 $h > 0$는 평활도(Smoothness)를 조절하는 초매개변수입니다. h가 너무 작으면 각각의 데이터 포인트 위에서 커널이 뾰족하게 솟아 과적합(Overfitting/Under-smoothing)이 발생하고, h가 너무 크면 세부 정보를 다 뭉개버려 과소적합(Underfitting/Over-smoothing)이 초래됩니다.

Citations

- Deisenroth, M. P., Faisal, A. A., & Ong, C. S. (2020). *Mathematics for Machine Learning*. Cambridge University Press. mml-book.pdf